DÉDICACE

À mes très chers parents,

Aucun hommage ne saurait exprimer l'immensité de l'amour, des sacrifices et de la bienveillance dont vous ne cessez de m'entourer. Que Dieu vous accorde santé, quiétude et longue vie. Je vous dédie ce travail en témoignage d'une infinie reconnaissance et d'une affection indéfectible.

À ma sœur, mon frère,

Pour votre soutien constant, vos encouragements chaleureux et votre présence réconfortante à chaque étape de mon cursus. Je vous souhaite un avenir resplendissant, couronné de succès et de félicité.

À mes chers amis et camarades de promotion,

Avec qui j'ai partagé les moments de doute, les défis intellectuels et les joies de la réussite. Votre esprit d'équipe et votre fidélité ont rendu ce parcours mémorable.

À tous ceux qui me sont chers, merci.

REMERCIEMENTS

Tout d'abord, je remercie Allah le Tout-Puissant de m'avoir accordé la force, la patience et la persévérance nécessaires pour mener à bien ce travail de fin d'études.

Je tiens à exprimer ma profonde gratitude à mon encadrant universitaire pour ses précieux conseils, sa rigueur scientifique et sa disponibilité exemplaire tout au long de ce projet. Sa clairvoyance et la qualité de ses orientations ont grandement contribué à la structuration et à l'aboutissement de ce mémoire.

J'adresse également mes plus vifs remerciements à mon encadrant au sein de WeData Consult pour son encadrement technique rigoureux, son écoute bienveillante et ses retours critiques hautement formateurs. Son accompagnement lors de l'intégration des flux de production et des architectures de données a été déterminant.

J'exprime toute ma reconnaissance aux membres du jury pour l'honneur qu'ils me font en acceptant d'évaluer ce travail de recherche et d'ingénierie logicielle.

Je tiens à remercier chaleureusement la Faculté des Sciences de Monastir, ainsi que l'ensemble du corps professoral du Master Data Science, pour la qualité de l'enseignement dispensé durant ces deux années de formation d'excellence.

Mes remerciements s'étendent enfin aux équipes d'ingénierie et d'atelier des sites industriels de Kondar, Sousse et Brno pour leur accueil et leur collaboration précieuse lors des phases de recueil des besoins et de validation terrain.

RÉSUMÉ

Dans le secteur de la plasturgie automobile, l'optimisation de la production et la gestion des approvisionnements constituent des enjeux majeurs pour améliorer la performance industrielle et assurer la continuité des activités. Face à la dispersion des données de production issues de plusieurs sites industriels, ce projet de fin d'études porte sur la conception et le déploiement de Nexora, une plateforme intégrée d'aide à la décision destinée au pilotage des activités industrielles.

La solution repose sur un entrepôt de données centralisé et un processus automatisé de collecte et de transformation des données. Elle s'articule autour de quatre piliers majeurs : l'ingénierie et l'assainissement automatisé des données d'atelier (ETL et Data Warehouse), le suivi des performances de production à travers des indicateurs industriels calculés directement sur l'entrepôt de données, la modélisation prédictive des cadences journalières avec sélection automatique du meilleur modèle, ainsi que l'optimisation intelligente de la gestion des stocks et la planification préventive des réapprovisionnements à 45 jours.

La plateforme exploite des méthodes d'apprentissage automatique pour anticiper les volumes de production et comparer chaque prévision à la production réelle de la même période de l'année précédente, tout en proposant une approche structurée de la gestion des stocks afin de limiter les risques de rupture. Les résultats sont présentés à travers des tableaux de bord interactifs et une interface web permettant de faciliter le suivi des indicateurs et la prise de décision.

Développée à l'aide de technologies de Business Intelligence, de traitement des données et de développement web, Nexora contribue à centraliser l'information, à améliorer la visibilité sur les opérations industrielles et à renforcer l'anticipation des besoins de production et d'approvisionnement.

Mots-clés : Système décisionnel, Business Intelligence, Data Science, Plasturgie automobile, Performance industrielle, Prévision de production, Validation croisée temporelle, Gestion des stocks, ETL, Data Warehouse, SQL Server, Power BI, React, Spring Boot.

ABSTRACT

In the automotive plastics manufacturing sector, production monitoring and raw material management are essential to improving industrial performance and ensuring operational continuity. This Master's thesis focuses on the design and implementation of Nexora, an integrated decision-support platform developed to improve production management and inventory planning across multiple industrial sites.

The platform relies on a centralized data warehouse and an automated Extract, Transform, Load (ETL) process to consolidate and prepare production data. It integrates four main pillars: automated data engineering and quality cleaning (ETL and Data Warehouse), production performance monitoring through industrial indicators, predictive modeling of daily workshop throughput with automatic selection of the best model, and intelligent inventory management with 45-day preventive replenishment planning.

Machine learning techniques are used to anticipate production volumes and compare each forecast with the actual production of the same period of the previous year. In parallel, the inventory management module helps prioritize replenishment needs and reduce the risk of stock shortages. The results are presented through a web application developed using React and Spring Boot and a Microsoft Power BI stock report, providing users with accessible information to support operational and strategic decision-making.

By combining Business Intelligence, data analytics, and web technologies, Nexora contributes to improving data visibility, production planning, and inventory management, while strengthening the integration of data-driven insights into daily industrial operations.

Keywords: Decision Support System, Business Intelligence, Data Science, Automotive Plastics Manufacturing, Industrial Performance, Production Forecasting, Time-Series Cross-Validation, Inventory Management, ETL, Data Warehouse, SQL Server, Power BI, React, Spring Boot.

TABLE DES MATIÈRES

Introduction générale **1**

1 Contexte et cadre du projet **3**
1.1 Introduction 3
1.2 Contexte académique 3
1.3 Présentation de l'organisme d'accueil 3
1.3.1 Présentation de l'entreprise 3
1.3.2 Domaines d'activité et contexte client 4
1.4 Présentation de la plateforme Nexora 4
1.4.1 Présentation générale 4
1.4.2 Fonctionnalités principales 5
1.4.3 Limites de la situation actuelle 5
1.5 Présentation du projet 6
1.5.1 Contexte et problématique 6
1.5.2 Étude de l'existant 6
1.5.3 Solution proposée 6
1.6 Workflow complet du projet 8
1.7 Méthodologie de développement 9
1.7.1 Étude comparative des méthodes 9
1.7.2 Choix méthodologique : Scrum 9
1.7.3 Organisation des rôles Scrum 10
1.7.4 Product Backlog 10
1.7.5 Planification des sprints 12
1.8 Langage et démarche de modélisation 12
1.9 Conclusion 13

2 Sprint 0 : Analyse des besoins et Conception du Système **14**
2.1 Introduction 14
2.2 Spécification des besoins 14
2.2.1 Besoins fonctionnels 14
2.2.2 Besoins non fonctionnels 14
2.3 Analyse des besoins 15
2.3.1 Identification des acteurs 15
2.3.2 Diagramme des cas d'utilisation global 15
2.4 Architecture globale du système 16
2.5 Environnement de travail 18
2.5.1 Environnement matériel 18
2.5.2 Environnement logiciel 18
2.6 Conclusion 19

3 Sprint 1 : Prétraitement des données, assainissement de la qualité et pipeline ETL20
3.1 Introduction 20

3.2 Présentation des données....20
3.2.1 Source des données....20
3.2.2 Description des tables du Data Warehouse....21
3.2.3 Modélisation dimensionnelle....21
3.3 Analyse exploratoire des données (EDA)....22
3.3.1 Analyse statistique de la production....22
3.3.2 Visualisation des séries temporelles....23
3.4 Conception et réalisation du pipeline ETL....25
3.4.1 Architecture du pipeline ETL....25
3.4.2 Extraction des données....26
3.4.3 Transformation et traitement des anomalies....26
3.4.4 Ajout de la colonne « Quantité produite TRS »....27
3.4.5 Chargement des données....27
3.5 Résultats du pipeline ETL....27
3.6 Bilan du Sprint 1....28
3.7 Conclusion....28

4 Sprint 2 : Développement du module de gestion intelligente des stocks....29
4.1 Introduction....29
4.2 Architecture fonctionnelle du module de gestion des stocks....29
4.3 Analyse des niveaux de stock et de la couverture....29
4.4 Classification opérationnelle et analyse de criticité des stocks....30
4.4.1 Typologie des statuts de stock et seuils d'autonomie....30
4.4.2 Répartition du catalogue et analyse de criticité....30
4.5 Génération des recommandations et chiffrage budgétaire....31
4.5.1 Algorithme de réapprovisionnement à horizon cible de 45 jours....31
4.5.2 Estimation du budget d'approvisionnement....31
4.5.3 Hiérarchisation des alertes d'atelier....32
4.6 Résultats obtenus....32
4.7 Bilan du Sprint 2....34
4.8 Conclusion....34

5 Sprint 3 : Modélisation prédictive par Intelligence Artificielle....35
5.1 Introduction....35
5.2 Démarche méthodologique de modélisation prédictive....35
5.3 Préparation des données et variables explicatives....36
5.3.1 Variable cible et préparation de la série....36
5.3.2 Variables explicatives et calendrier industriel....36
5.3.3 Validation croisée temporelle (origine glissante)....37
5.4 Métriques d'évaluation de la performance....37
5.5 Développement des modèles d'intelligence artificielle....38
5.5.1 Régression Linéaire Simple....38
5.5.2 Modèle ARIMA....38
5.5.3 Modèle Random Forest Regressor....39

5.5.4 Modèle Prophet (Meta)..... 39
5.6 Réglage des hyperparamètres..... 40
5.7 Résultats comparatifs et sélection du modèle..... 41
5.8 Prévision opérationnelle et comparaison avec l'année précédente..... 42
5.9 Limites et robustesse des prévisions..... 43
5.10 Rôles respectifs des modèles dans la plateforme Nexora..... 43
5.11 Bilan du Sprint 3..... 44
5.12 Conclusion..... 44

6 Sprint 4 : Développement du tableau de bord décisionnel et validation..... 45
6.1 Introduction..... 45
6.2 Architecture du tableau de bord et intégration applicative..... 45
6.3 Portail web et rapport Power BI..... 46
6.3.1 Tableau de bord principal et suivi de la production..... 46
6.3.2 Pages de prévision (Data Science et Benchmark)..... 46
6.3.3 Page Stock et rapport Power BI « Suivi stock »..... 46
6.4 Présentation du rapport Power BI « Suivi stock »..... 47
6.4.1 Valeur du stock par famille..... 47
6.4.2 Historique et répartition des stocks d'atelier..... 47
6.4.3 Top 10 des articles par site..... 48
6.4.4 Détail du stock à date..... 49
6.4.5 Portail web opérationnel..... 49
6.5 Validation des résultats..... 50
6.5.1 Validation des prévisions d'atelier..... 50
6.5.2 Validation des règles d'approvisionnement..... 50
6.6 Bilan du Sprint 4..... 50
6.7 Conclusion..... 51

Conclusion générale et perspectives..... 52
Bibliographie..... 55

TABLE DES FIGURES

Figure 1.1 : Logo de la plateforme Nexora..... 4
Figure 1.2 : Workflow complet du système décisionnel Nexora..... 8
Figure 1.3 : Cycle itératif de la méthodologie Agile Scrum..... 10
Figure 2.1 : Diagramme des cas d'utilisation global de Nexora..... 16
Figure 2.2 : Architecture globale du système décisionnel en quatre couches..... 17
Figure 3.1 : Tables du Data Warehouse dbDWH et relations exploitées par Nexora..... 22
Figure 3.2 : Production journalière réelle (quantité TRS) du 01/01/2024 au 26/03/2026..24
Figure 3.3 : Production moyenne par jour de semaine et par mois..... 24
Figure 3.4 : Production moyenne selon le mois et le jour de semaine..... 25
Figure 3.5 : Architecture et flux séquentiel du pipeline ETL..... 26
Figure 4.1 : Répartition des 1 410 articles suivis par statut de stock.....33
Figure 4.2 : Articles en rupture et en stock critique par famille (GroupeItem)..... 33
Figure 5.1 : Prévision de février 2026 (Random Forest) et production réelle.....42
Figure 5.2 : Prévision de mai 2026 et production de mai 2025..... 43
Figure 6.1 : Architecture globale d'intégration et de déploiement de Nexora..... 45
Figure 6.2 : Rapport Power BI « Suivi stock » – page Stock par famille.....47
Figure 6.3 : Rapport Power BI « Suivi stock » – page Historique de stock..... 48
Figure 6.4 : Rapport Power BI « Suivi stock » – page Vue globale (état de stock)..... 48
Figure 6.5 : Rapport Power BI « Suivi stock » – page Top 10 par site..... 49
Figure 6.6 : Rapport Power BI « Suivi stock » – page Détail stock (stock à date)..... 49

LISTE DES TABLEAUX

Tableau 1.1 : Positionnement comparatif des solutions existantes avec Nexora..... 8
Tableau 1.2 : Comparaison entre approche classique et approche agile..... 9
Tableau 1.3 : Avantages et inconvénients des méthodologies.....9
Tableau 1.4 : Product Backlog priorisé du projet..... 12
Tableau 1.5 : Planification des sprints du projet..... 12
Tableau 2.1 : Les besoins non fonctionnels du système..... 15
Tableau 2.2 : Outils, langages et bibliothèques logiciels utilisés..... 19
Tableau 3.1 : Périmètre quantitatif des données industrielles du projet..... 21
Tableau 3.2 : Structure des tables du Data Warehouse Nexora.....21
Tableau 3.3 : Statistiques descriptives de la série journalière de production..... 23
Tableau 3.4 : Effet du calendrier sur la production journalière..... 23
Tableau 3.5 : Cascade de rétention du pipeline ETL (862 065 lignes).....26
Tableau 3.6 : Résultats quantitatifs et techniques du pipeline ETL.....28
Tableau 3.7 : Bilan des livrables du Sprint 1..... 28
Tableau 4.1 : Classification des produits selon le niveau de couverture disponible..... 30
Tableau 4.2 : Bilan des livrables du Sprint 2..... 34
Tableau 5.1 : Variables utilisées par chaque modèle..... 36
Tableau 5.2 : Protocole de validation temporelle.....37
Tableau 5.3 : Avantages et limites : Régression Linéaire.....38
Tableau 5.4 : Avantages et limites : Modèle ARIMA..... 39
Tableau 5.5 : Avantages et limites : Random Forest..... 39
Tableau 5.6 : Avantages et limites : Prophet.....40
Tableau 5.7 : Réglages testés et résultats..... 40
Tableau 5.8 : Effet du réglage sur la validation N-1 (mai 2025)..... 41
Tableau 5.9 : Performances des modèles (validation croisée et mai 2025).....41
Tableau 5.10 : Bilan des livrables du Sprint 3..... 44
Tableau 6.1 : Bilan des livrables du Sprint 4..... 51

LISTE DES ABRÉVIATIONS

Abréviation	Signification en Français	Définition / Contexte Industriel
API	Application Programming Interface	Interface de programmation applicative pour l'échange de données inter-services
ARIMA	AutoRegressive Integrated Moving Average	Modèle statistique autorégressif intégré ; ici d'ordre 7 pour suivre le rythme hebdomadaire
BI	Business Intelligence	Informatique décisionnelle pour l'aide au pilotage et au reporting exécutif
CV	Cross-Validation (Validation Croisée)	Méthode d'évaluation statistique par partitionnement chronologique des données
DAX	Data Analysis Expressions	Langage de formules et de calculs analytiques utilisé dans Microsoft Power BI
ERP	Enterprise Resource Planning	Progiciel de gestion intégré de l'entreprise (Microsoft Dynamics NAV)
ETL	Extract, Transform, Load	Pipeline d'extraction, assainissement, enrichissement et chargement des données
IA	Intelligence Artificielle	Ensemble des techniques et algorithmes d'apprentissage automatique
MAE	Mean Absolute Error	Erreur absolue moyenne exprimée en unités produites par jour
MES	Manufacturing Execution System	Système de pilotage et d'exécution des ateliers de fabrication
ML	Machine Learning	Apprentissage automatique supervisé et non supervisé
RBAC	Role-Based Access Control	Contrôle d'accès aux fonctionnalités fondé sur les rôles (Opérateur, Administrateur)
RMSE	Root Mean Square Error	Racine carrée de l'erreur quadratique moyenne pénalisant les grands écarts
SQL	Structured Query Language	Langage de requêtage relationnel (Microsoft SQL Server)
TND	Dinar Tunisien	Unité monétaire légale pour la valorisation financière des stocks
TRS	Taux de Rendement Synthétique	Quantité de pièces bonnes produites, calculée par le pipeline ETL dans FACT_CLE (variable cible des prévisions)
UML	Unified Modeling Language	Langage universel de modélisation visuelle des systèmes logiciels

INTRODUCTION GÉNÉRALE

La compétitivité et la résilience des entreprises manufacturières reposent sur leur capacité à transformer les flux de données industrielles en leviers décisionnels tangibles. Dans le secteur de la plasturgie automobile, caractérisé par des cadences de production élevées, des exigences strictes de qualité et des flux tendus, la maîtrise conjointe de la cadence de fabrication et des approvisionnements en matières premières constitue un enjeu économique et opérationnel déterminant.

Ce projet de fin d'études, mené en collaboration avec la société WeData Consult, s'inscrit dans le cadre de l'accompagnement d'un équipementier automobile international exploitant plusieurs sites industriels en Tunisie et en Europe. Bien que l'entreprise dispose d'un entrepôt de données centralisant l'historique de ses ateliers [16], l'exploitation de ce patrimoine informationnel demeurait fragmentée. Le pilotage opérationnel reposait essentiellement sur des extractions manuelles différées, privant les décideurs d'une visibilité en temps réel. Parallèlement, l'absence d'outils prédictifs rendait la gestion des stocks vulnérable aux aléas, générant conjointement des risques de rupture sur des composants stratégiques et des immobilisations financières en surstock.

Face à ces constats, la problématique centrale de ce travail s'énonce ainsi :

« Comment valoriser les données massives d'un entrepôt industriel à travers des approches d'apprentissage automatique et d'informatique décisionnelle pour optimiser la supervision de la production, anticiper les cadences d'atelier et sécuriser la gestion des approvisionnements ? »

Pour répondre à cette problématique, nous avons conçu et développé la solution Nexora, une plateforme décisionnelle intégrant la chaîne complète de valorisation de la donnée :

- L'ingénierie et l'assainissement des données (ETL) : conception d'un pipeline automatisé assurant la qualité, l'intégrité et la structuration dimensionnelle des données industrielles multi-sites.
- La modélisation prédictive par Machine Learning : développement et évaluation comparative de modèles statistiques et d'apprentissage automatique (Régression Linéaire, ARIMA, Random Forest, Prophet), évalués par validation croisée

temporelle, pour anticiper les cadences de fabrication sur un horizon mensuel opérationnel.

- L'aide à la décision et l'optimisation logistique : segmentation analytique du catalogue d'articles, évaluation dynamique de la couverture de stock et modélisation de plans de réapprovisionnement préventifs [14, 15].
- La restitution analytique multi-profils : déploiement d'un portail web réactif (React.js [22], Spring Boot [17], FastAPI [21]) pour le pilotage de la production, des stocks et des prévisions, complété par un rapport Microsoft Power BI [24] de suivi des stocks.

Conduit selon la méthodologie Agile Scrum [1, 2], le projet a été structuré autour d'un sprint de cadrage (Sprint 0) et de quatre sprints de réalisation. Le présent mémoire s'organise en six chapitres :

- Le chapitre 1 introduit le contexte académique et industriel du projet, l'étude comparative de l'existant, la méthodologie Scrum et les démarches de modélisation retenues [25].
- Le chapitre 2 (Sprint 0) est dédié à l'analyse des besoins fonctionnels et non fonctionnels, à la conception de l'architecture en quatre couches et au choix de l'environnement technique.
- Le chapitre 3 (Sprint 1) détaille l'exploration statistique des données (EDA), l'audit qualité et la réalisation du pipeline ETL alimentant le Data Warehouse.
- Le chapitre 4 (Sprint 2) présente le module de gestion intelligente des stocks, la classification opérationnelle par niveau de couverture et l'estimation des besoins de réapprovisionnement.
- Le chapitre 5 (Sprint 3) expose la démarche de modélisation prédictive des cadences : validation croisée temporelle, réglage des hyperparamètres et sélection automatique du meilleur modèle pour chaque mois.
- Le chapitre 6 (Sprint 4) décrit le portail web opérationnel, le rapport Power BI de suivi des stocks et la validation des prévisions et des règles d'approvisionnement.

Enfin, une conclusion générale récapitule les principaux apports de cette étude, en discute les limites méthodologiques et esquisse des perspectives d'évolution pour le secteur industriel.

CHAPITRE 1 : CONTEXTE ET CADRE DU PROJET

1.1 Introduction

Ce premier chapitre présente le cadre général de notre projet de fin d'études. Nous décrivons d'abord le contexte académique au sein de la Faculté des Sciences de Monastir, puis la collaboration entre l'organisme d'accueil, la société WeData Consult, et l'équipementier industriel partenaire spécialisé dans la plasturgie automobile. Nous analysons ensuite les problématiques opérationnelles rencontrées dans les ateliers d'injection plastique, les limites des outils existants et la solution Nexora conçue pour y répondre. Enfin, nous présentons la démarche méthodologique Agile Scrum et les démarches de modélisation retenues pour encadrer le développement du système.

1.2 Contexte académique

Ce projet est réalisé dans le cadre du Master Professionnel en Data Science de la Faculté des Sciences de Monastir (FSM), rattachée à l'Université de Monastir. Cette formation d'excellence prépare les étudiants à l'ingénierie des données massives, au développement d'algorithmes d'apprentissage automatique et à l'intégration de solutions logicielles d'aide à la décision.

Ce travail de fin d'études permet d'appliquer les compétences acquises en science des données à un environnement industriel complexe, en exploitant des données réelles issues d'un parc de 319 machines réparties sur plusieurs sites de production.

1.3 Présentation de l'organisme d'accueil

1.3.1 Présentation de l'entreprise

Ce projet a été réalisé au sein de WeData Consult, une société de conseil en systèmes d'information située à Sousse, en Tunisie (Immeuble Safa 3, Sahloul 1). Avec pour devise « The partner of your data », elle est dirigée par deux associés qui cumulent plus de quinze ans d'expérience dans l'intégration de progiciels de gestion intégrée (ERP) en Tunisie et à l'international. WeData Consult accompagne ses clients en matière de conseil, d'intégration, de support et de formation, afin de leur garantir un système d'information performant.

1.3.2 Domaines d'activité et contexte client

L'offre de WeData Consult s'organise autour de trois pôles :

- Solutions d'entreprise : intégration et mise en place d'ERP, notamment Microsoft Dynamics NAV, Microsoft Dynamics 365 Business Central et Axelor, selon la méthodologie Microsoft Dynamics Sure Step.
- Solutions BI : collecte, organisation et analyse des données pour l'aide à la décision, avec des outils tels que Microsoft Power BI, Tableau Software et SSIS.
- Infogérance et infrastructure : gestion du parc informatique des clients afin d'améliorer les performances de leur système d'information.

L'entreprise met en avant trois valeurs : la qualité, avec des équipes certifiées par des institutions internationales comme Microsoft, la réactivité et l'expertise. Ses équipes réunissent des administrateurs système, des développeurs et des consultants métiers.

Dans le cadre de ce projet, WeData Consult intervient auprès d'un équipementier automobile disposant de sites de production en Tunisie (Kondar et Sousse) et en République tchèque (Brno), spécialisé dans la fabrication de pièces plastiques injectées.

1.4 Présentation de la plateforme Nexora

1.4.1 Présentation générale

Nexora est une solution logicielle d'aide à la décision conçue pour faciliter le suivi des ateliers d'injection plastique et la gestion proactive des approvisionnements de stock. Elle s'appuie sur les données centralisées dans le Data Warehouse pour proposer des indicateurs de production calculés directement sur le Data Warehouse (actualisés toutes les 10 minutes), des prévisions de cadence de production par apprentissage automatique et des recommandations quantifiées de réapprovisionnement.



Figure 1.1 : Logo de la plateforme Nexora

La solution s'adresse aux équipes industrielles selon deux profils d'utilisateurs clairement délimités : les Administrateurs (supervision des presses, pilotage des flux, gestion des approvisionnements et des modèles) et les Opérateurs (consultation des stocks d'atelier, filtrage des alertes de rupture et suivi des indicateurs de production).

1.4.2 Fonctionnalités principales

La plateforme Nexora s'articule autour de quatre fonctionnalités majeures :

- Supervision du parc machines : suivi des 319 machines du référentiel (actives et bloquées) réparties sur les sites de Kondar, Sousse et Brno, avec des indicateurs de production consolidés par mois, par année ou sur tout l'historique.
- Prévision des volumes de fabrication : estimation de la production journalière pour le mois choisi par le meilleur de quatre modèles, sélectionné automatiquement, afin de guider l'ordonnancement des équipes et des approvisionnements matières.
- Gestion prévisionnelle des stocks : classification opérationnelle des références du catalogue par niveau de criticité (Rupture, Critique, Normal, Surstock, Sans consommation, Inactif) et calcul des réapprovisionnements nécessaires pour sécuriser une couverture cible de 45 jours.
- Restitution décisionnelle interactive : portail web (tableau de bord, production, machines, stock et prévisions) complété par un rapport Power BI de suivi des stocks filtrable par site, famille et date.

1.4.3 Limites de la situation actuelle

Avant la conception de Nexora, le pilotage industriel présentait plusieurs contraintes méthodologiques et opérationnelles :

- Suivi manuel et différé de l'activité : les feuilles d'enregistrement remplies par les opérateurs étaient consolidées mensuellement sur tableur, empêchant une détection rapide des ralentissements ou des baisses anormales de cadence.
- Gestion réactive des réapprovisionnements : les commandes de granulés polymères étaient fréquemment déclenchées en réaction à une alerte visuelle de pénurie en atelier, générant des risques de rupture ou de surcoûts logistiques d'urgence.
- Présence conjointe de ruptures et de surstocks : l'absence d'outils analytiques entraînait une sur-couverture sur certaines références à faible rotation

(immobilisation de trésorerie), tandis que des références critiques tombaient en rupture.

- Fragmentation des sources d'information : les données de production, d'en-cours et d'inventaire étaient dispersées dans l'ERP, rendant leur croisement complexe pour les décideurs.

1.5 Présentation du projet

1.5.1 Contexte et problématique

L'entreprise partenaire dispose d'un Data Warehouse conservant l'historique complet des déclarations de production et des instantanés d'inventaire. Toutefois, ces données massives demeuraient sous-exploitées pour anticiper les charges futures et guider la chaîne logistique.

La problématique centrale du projet se formule ainsi :

« Comment valoriser les données centralisées du Data Warehouse industriel pour concevoir un système décisionnel automatisé, capable de superviser l'activité des presses, de modéliser les cadences par apprentissage automatique et d'optimiser les politiques de réapprovisionnement de stock ? »

1.5.2 Étude de l'existant

En milieu industriel, trois approches coexistent couramment : les feuilles de calcul bureautiques (Excel), les modules de base des progiciels de gestion intégrée (ERP) et les systèmes de pilotage d'atelier (Manufacturing Execution System – MES). Les tableurs, bien que flexibles, sont exposés aux erreurs de saisie et peu adaptés aux gros volumes de données. Les ERP enregistrent les transactions (achats, stocks, production) mais offrent peu d'analyse. Les MES suivent l'exécution de la production en temps réel ; ils demandent un investissement important et ne couvrent généralement pas en standard la prévision des volumes ni la gestion prévisionnelle des stocks.

1.5.3 Solution proposée

Pour concilier agilité décisionnelle, rigueur méthodologique et intégration opérationnelle fluide, la solution Nexora s'articule autour de trois piliers complémentaires :

- 1. L'ingénierie et l'intégration des données : un pipeline automatisé de collecte et d'assainissement des données industrielles garantissant l'intégrité des informations avant leur consolidation dans un entrepôt de données relationnel structuré.
- 2. La modélisation prédictive des cadences : un moteur analytique exploitant des modèles d'apprentissage automatique pour anticiper les volumes de production, comparer chaque prévision à la production réelle de l'année précédente et sécuriser la planification d'atelier.
- 3. La gestion préventive des approvisionnements : un module décisionnel associant segmentation multicritère du catalogue et calcul dynamique des réapprovisionnements nécessaires pour prévenir les ruptures critiques tout en évitant les surstocks immobilisants.

L'architecture de restitution associe une application web (React.js / Spring Boot / FastAPI) pour le pilotage de la production, des stocks et des prévisions, et un rapport Microsoft Power BI pour l'analyse détaillée des stocks.

Le tableau 1.1 résume le positionnement comparatif des solutions existantes vis-à-vis de Nexora :

Critère d'évaluation	Progiciels MES standards	ERP transactionnel	Tableurs (Excel)	Solution Nexora
Supervision des cadences atelier	Avancé	Limité	Manuel / Différé	Automatisé (mois / année / historique)
Prévisions de cadence par IA	Rarement en standard	Limité (extensions)	Non proposé	Intégré (meilleur de 4 modèles)
Tableaux de bord interactifs	Configurable	Limité	Statique	Interactif (React + Power BI)
Intégration directe au Data Warehouse	Complexe	Source des données	Import manuel	Directe (Schéma relationnel)
Gestion et criticité des stocks	Partiel	Standard	Manuel	Par couverture (Rupture / Critique / Normal / Surstock)
Recommandations d'approvisionnement	Non couvert	Sur seuils statiques	Manuel	Calcul de couverture dynamique
Facilité d'appropriation atelier	Moyenne	Complexe	Accessible	Interface adaptée
Agilité et coût de déploiement	Investissement élevé	Coût élevé	Faible	Modulaire et maîtrisé

Tableau 1.1 : Positionnement comparatif des solutions existantes avec Nexora

1.6 Workflow complet du projet

Le traitement des données et la restitution des résultats suivent un enchaînement méthodique en huit étapes, illustré par la figure 1.2 :

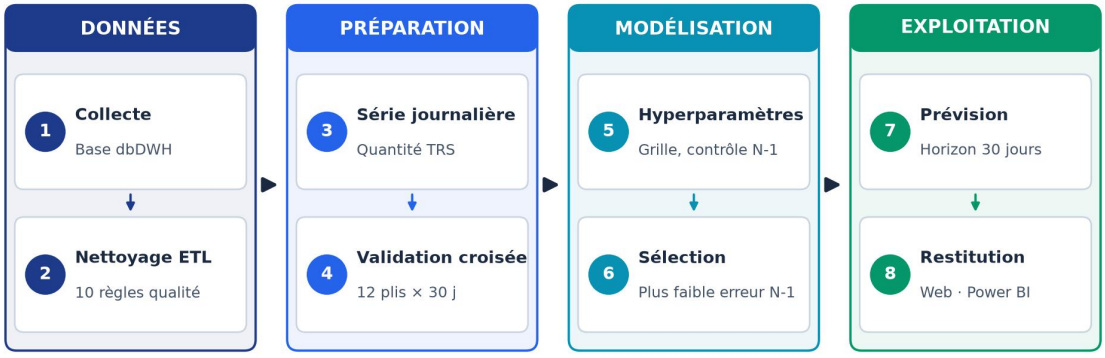


Figure 1.2 : Workflow complet du système décisionnel Nexora

- 1. Ingestion des données brutes : extraction des données d'inventaire et de production issues du système d'information industriel.
- 2. Nettoyage des données (ETL) : suppression des doublons, rejet des dates invalides et correction des incohérences de stock.
- 3. Préparation de la série : agrégation journalière de la quantité produite TRS, plafonnement des valeurs extrêmes, jours fériés tunisiens et fermetures récurrentes apprises.
- 4. Validation croisée temporelle : 12 plis glissants de 30 jours, chaque pli n'étant entraîné que sur les jours qui le précèdent.
- 5. Réglage des hyperparamètres : recherche sur grille par validation croisée (6 plis de 30 jours) ou par AIC, contrôlée sur l'année précédente.
- 6. Sélection du modèle : le modèle retenu est celui qui obtient la plus faible erreur moyenne (MAE) sur le même mois de l'année précédente (mai 2025 pour une prévision de mai 2026).
- 7. Prévision et mesure des performances : prévision du mois choisi et calcul des erreurs (MAE, RMSE, R^2) en unités produites par jour.
- 8. Restitution utilisateur : application web React / Spring Boot et rapport Power BI de suivi des stocks.

1.7 Méthodologie de développement

1.7.1 Étude comparative des méthodes

Avant d'entamer les développements, nous avons comparé la méthode classique en cascade et la démarche Agile (tableau 1.2) :

Critère	Approche classique (Cascade)	Approche Agile (Scrum)
Cycle de développement	Linéaire et séquentiel	Itératif, par incréments réguliers
Planification	Figée au démarrage	Ajustable selon l'avancement réel
Livrables	Livraison globale en fin de projet	Incrément fonctionnel à chaque sprint
Prise en compte des retours	Tardive, en phase de recette	Continue, à chaque fin d'itération
Principale limite	Peu flexible face aux anomalies de données	Exige une disponibilité régulière des encadrants

Tableau 1.2 : Comparaison entre approche classique et approche agile

Le tableau 1.3 récapitule les avantages et limites des deux méthodologies :

Méthodologie	Avantages principaux	Inconvénients principaux
Approche classique	• Cadre et jalons contractuels nettement fixés. • Simplicité de contractualisation initiale.	• Faible flexibilité face aux anomalies de données. • Risque de décalage avec les attentes d'atelier.
Approche Agile (Scrum)	• Adaptabilité forte aux spécificités des séries réelles. • Validation progressive et mesurable de chaque module. • Rétroactions régulières avec les encadrants.	• Exige une disponibilité continue des parties prenantes. • Nécessite une discipline stricte sur la tenue du backlog.

Tableau 1.3 : Avantages et inconvénients des méthodologies

1.7.2 Choix méthodologique : Scrum

Nous avons sélectionné le framework Agile Scrum [1, 2], particulièrement approprié aux projets décisionnels et de science des données combinant plusieurs briques interdépendantes (ETL, algorithmes prédictifs, règles logistiques et restitution visuelle).

Ce cadre itératif favorise l'ajustement continu des modèles en fonction de la qualité observée des données et permet de valider chaque composant logiciel auprès des encadrants.

La figure 1.3 illustre le cycle de déroulement de la méthodologie Scrum appliquée à notre projet :

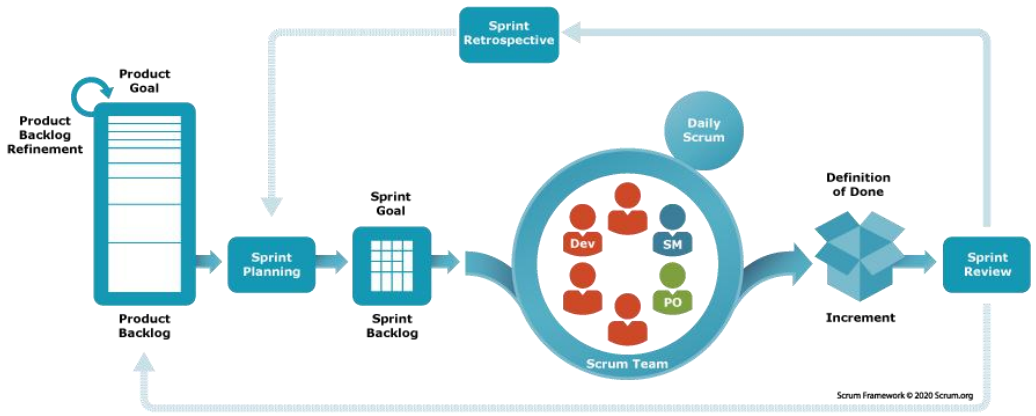


Figure 1.3 : Cycle itératif de la méthodologie Agile Scrum

1.7.3 Organisation des rôles Scrum

Pour concilier la rigueur académique d'un travail de Master et les exigences industrielles de l'atelier, les rôles Scrum ont été répartis de la manière suivante :

- Product Owner (PO) : assumé par l'encadrant professionnel au sein de WeData Consult en lien avec l'équipe de l'usine partenaire. Il exprime les besoins fonctionnels, priorise les récits utilisateurs du backlog et valide les incréments à chaque revue de sprint.
- Scrum Master (SM) : assuré par l'encadrant académique à la Faculté des Sciences de Monastir. Il veille au respect du cadre méthodologique Agile, garantit la rigueur scientifique des protocoles de validation et aide à lever les blocages conceptuels.
- Équipe de Développement (Development Team) : incarnée par l'étudiante chercheuse, responsable de la conception technique, du développement du pipeline ETL, de l'expérimentation des algorithmes d'apprentissage et de la réalisation des interfaces.

1.7.4 Product Backlog

Le Product Backlog (tableau 1.4) regroupe les récits utilisateurs (User Stories) formalisant les exigences du système, priorisés et estimés pour chaque sprint. Les récits fonctionnels sont portés par les deux utilisateurs de la plateforme (l'Administrateur et

l'Opérateur) ; les récits techniques de préparation des données et de modélisation sont portés par le data scientist de l'équipe projet, qui n'est pas un utilisateur de l'application :

ID	Récit Utilisateur (User Story)	Priorité	Estimation	Sprint Associé
US01	En tant que data scientist, je veux vérifier la qualité des données brutes afin de détecter les doublons et les anomalies	Haute	3 jours	Sprint 1
US02	En tant que data scientist, je veux nettoyer les données avec un pipeline ETL afin d'obtenir des données fiables	Haute	4 jours	Sprint 1
US03	En tant que data scientist, je veux organiser les données nettoyées dans le Data Warehouse afin de faciliter leur analyse	Haute	3 jours	Sprint 1
US04	En tant que data scientist, je veux charger les données nettoyées dans SQL Server afin de les rendre accessibles à la plateforme	Haute	2 jours	Sprint 1
US05	En tant que data scientist, je veux préparer la série journalière de production afin d'alimenter les modèles de prévision	Haute	3 jours	Sprint 1
US06	En tant qu'administrateur, je veux classer les articles selon leur niveau de risque afin d'identifier les priorités d'approvisionnement	Haute	3 jours	Sprint 2
US07	En tant qu'administrateur, je veux analyser la répartition des stocks par famille et par site afin de mieux piloter l'inventaire	Moyenne	3 jours	Sprint 2
US08	En tant qu'opérateur, je veux consulter le stock de chaque article par site afin d'anticiper les ruptures	Haute	2 jours	Sprint 2
US09	En tant qu'opérateur, je veux consulter le nombre d'articles en rupture afin de réagir rapidement	Haute	2 jours	Sprint 2
US10	En tant qu'administrateur, je veux calculer les quantités à commander afin de sécuriser une couverture de 45 jours	Haute	3 jours	Sprint 2
US11	En tant qu'administrateur, je veux estimer le budget de réapprovisionnement afin de planifier les achats prioritaires	Moyenne	2 jours	Sprint 2
US12	En tant que data scientist, je veux évaluer les modèles par validation croisée temporelle afin de mesurer leur fiabilité	Haute	2 jours	Sprint 3
US13	En tant que data scientist, je veux comparer les modèles de prévision afin de retenir le plus fiable	Haute	4 jours	Sprint 3
US14	En tant que data scientist, je veux régler les hyperparamètres des modèles afin d'améliorer leur précision	Haute	3 jours	Sprint 3
US15	En tant qu'administrateur, je veux prévoir la production journalière du mois choisi afin d'organiser les équipes et les approvisionnements	Haute	3 jours	Sprint 3
US16	En tant qu'administrateur, je veux comparer la prévision à la production réelle afin de vérifier sa fiabilité	Haute	3 jours	Sprint 3
US17	En tant qu'utilisateur, je veux me connecter de manière sécurisée afin d'accéder aux fonctionnalités de mon rôle	Haute	3 jours	Sprint 4
US18	En tant qu'administrateur, je veux suivre la production et le parc machines sur le tableau de bord afin de détecter rapidement les baisses d'activité	Haute	4 jours	Sprint 4
US19	En tant qu'administrateur, je veux analyser l'évolution des stocks dans Power BI afin d'appuyer mes décisions	Haute	4 jours	Sprint 4
US20	En tant qu'opérateur, je veux rechercher et exporter l'état	Moyenne	3 jours	Sprint 4

ID	Récit Utilisateur (User Story)	Priorité	Estimation	Sprint Associé
	des stocks afin de partager les informations d'atelier			
US21	En tant qu'administrateur, je veux gérer les comptes des utilisateurs afin de contrôler l'accès à la plateforme	Moyenne	2 jours	Sprint 4

Tableau 1.4 : Product Backlog priorisé du projet

1.7.5 Planification des sprints

Le projet s'est déroulé sur une période de 13 semaines articulée en un sprint de cadrage initial (Sprint 0) et quatre sprints de développement d'une durée de 2 à 3 semaines chacun (tableau 1.5) :

Sprint	Objectif principal	Livrables clés validés
Sprint 0	Cadrage des besoins et architecture globale	Spécifications fonctionnelles, cas d'utilisation UML et architecture logicielle.
Sprint 1	Qualité des données et pipeline ETL	Pipeline Python de nettoyage, tables cibles, ajout de la quantité TRS et chargement des données validées.
Sprint 2	Gestion intelligente des stocks	Classification par niveau de criticité, seuils d'alerte, règles de réapprovisionnement et estimation budgétaire.
Sprint 3	Modélisation prédictive par IA	Validation croisée temporelle, réglage des hyperparamètres, comparaison des quatre modèles et sélection automatique du meilleur modèle.
Sprint 4	Restitution décisionnelle et validation	Portail web React / Spring Boot, rapport Power BI de suivi des stocks et validation des résultats.

Tableau 1.5 : Planification des sprints du projet

1.8 Langage et démarche de modélisation

Pour modéliser la structure et le comportement du système avec rigueur et clarté, nous mobilisons le langage standard UML (Unified Modeling Language) [25] pour le cadrage fonctionnel, complété par les représentations de flux propres aux projets de Data Science. Trois types de représentations graphiques sont principalement employés dans ce rapport :

- Diagramme de cas d'utilisation global (Chapitre 2) : formalisation synthétique des services offerts aux deux acteurs du système (Opérateur d'atelier et Administrateur), avec identification des relations d'inclusion d'authentification.
- Modélisation dimensionnelle et relationnelle (Chapitre 3) : schéma conceptuel et relationnel de l'entrepôt de données (Data Warehouse) articulant la table de faits d'atelier et les dimensions associées.

- Cartographies d'architecture et flux de données (Chapitres 2, 3 et 6) : description modulaire des couches du système décisionnel, du pipeline séquentiel ETL et de l'intégration globale de la plateforme.

1.9 Conclusion

Ce premier chapitre a posé les fondations du projet Nexora. Après avoir situé le cadre académique et la collaboration entre WeData Consult et l'équipementier automobile, nous avons formalisé la problématique du pilotage d'atelier et présenté l'organisation itérative Scrum adoptée. Le chapitre suivant détaille les résultats du Sprint 0, consacré à la spécification des besoins et à la conception de l'architecture globale en quatre couches.

CHAPITRE 2 : SPRINT 0 : ANALYSE DES BESOINS ET CONCEPTION DU SYSTÈME

2.1 Introduction

Ce chapitre correspond au Sprint 0 de notre démarche Scrum. Cette étape de cadrage initial a pour objectif de formaliser les exigences du système Nexora, d'identifier les profils d'utilisateurs et leurs interactions avec la plateforme, de concevoir l'architecture globale en quatre couches et de définir l'environnement technique retenu pour le développement.

2.2 Spécification des besoins

La spécification des besoins permet de traduire les attentes des équipes d'atelier en fonctionnalités logicielles concrètes. Nous distinguons les besoins fonctionnels, qui précisent les services fournis par le système, des besoins non fonctionnels, qui définissent les critères de qualité technique et de performance.

2.2.1 Besoins fonctionnels

Les fonctionnalités attendues sont organisées selon les deux profils d'utilisateurs du système :

- L'Opérateur : acteur d'atelier habilité à consulter l'état des stocks réels, filtrer les alertes de criticité par site et suivre les indicateurs de fabrication des presses.
- L'Administrateur : superviseur d'atelier et responsable logistique. Il assure le pilotage opérationnel (supervision du parc machines, suivi des ordres de fabrication, suivi des cadences d'atelier, consultation des prévisions mensuelles d'IA) ainsi que l'administration technique (gestion des comptes et contrôle d'accès RBAC).

2.2.2 Besoins non fonctionnels

Le tableau 2.1 récapitule les exigences non fonctionnelles retenues pour guider la conception de la solution :

Catégorie	Exigence	Critère de vérification
Performance	Temps de réponse inférieur à 2 secondes pour les tableaux de bord (cache applicatif) ; calcul complet	Mesures de temps de réponse et fluidité des

Catégorie	Exigence	Critère de vérification
	des prévisions en une à deux minutes, puis mis en cache.	affichages.
Sécurité	Connexion sécurisée, mots de passe chiffrés et droits d'accès selon le rôle (administrateur ou opérateur).	Contrôle des permissions Opérateur / Admin.
Fiabilité	Données d'entrée assainies par le pipeline ETL et modèles de prévision rigoureusement validés.	Zéro doublon résiduel dans le Data Warehouse et cohérence des résultats.
Maintenabilité	Architecture modulaire découplée en 4 couches avec séparation nette entre ETL, modélisation et restitution.	Code versionné et documenté.
Évolutivité	Capacité d'intégrer ultérieurement des modèles de prévision par machine ou de nouvelles sources de données sans refonte.	Schéma dimensionnel normalisé.
Ergonomie	Tableaux de bord visuels intuitifs et interface web réactive adaptée aux postes d'atelier.	Navigation fluide et lisibilité opérationnelle.

Tableau 2.1 : Les besoins non fonctionnels du système

2.3 Analyse des besoins

2.3.1 Identification des acteurs

L'analyse des cas d'utilisation met en évidence deux acteurs intervenant sur la plateforme Nexora :

- 1. L'Opérateur : acteur opérationnel en atelier, responsable du suivi des stocks d'atelier, du filtrage des alertes de couverture et de la consultation d'avancement des ordres de fabrication.
- 2. L'Administrateur : acteur de gestion et de supervision, assurant le pilotage d'atelier (supervision des presses, consultation des cadences et des prévisions IA, gestion des alertes d'approvisionnement) ainsi que l'administration des accès.

2.3.2 Diagramme des cas d'utilisation global

La figure 2.1 présente le diagramme de cas d'utilisation global de la plateforme Nexora, illustrant les interactions entre les deux acteurs et les modules applicatifs :

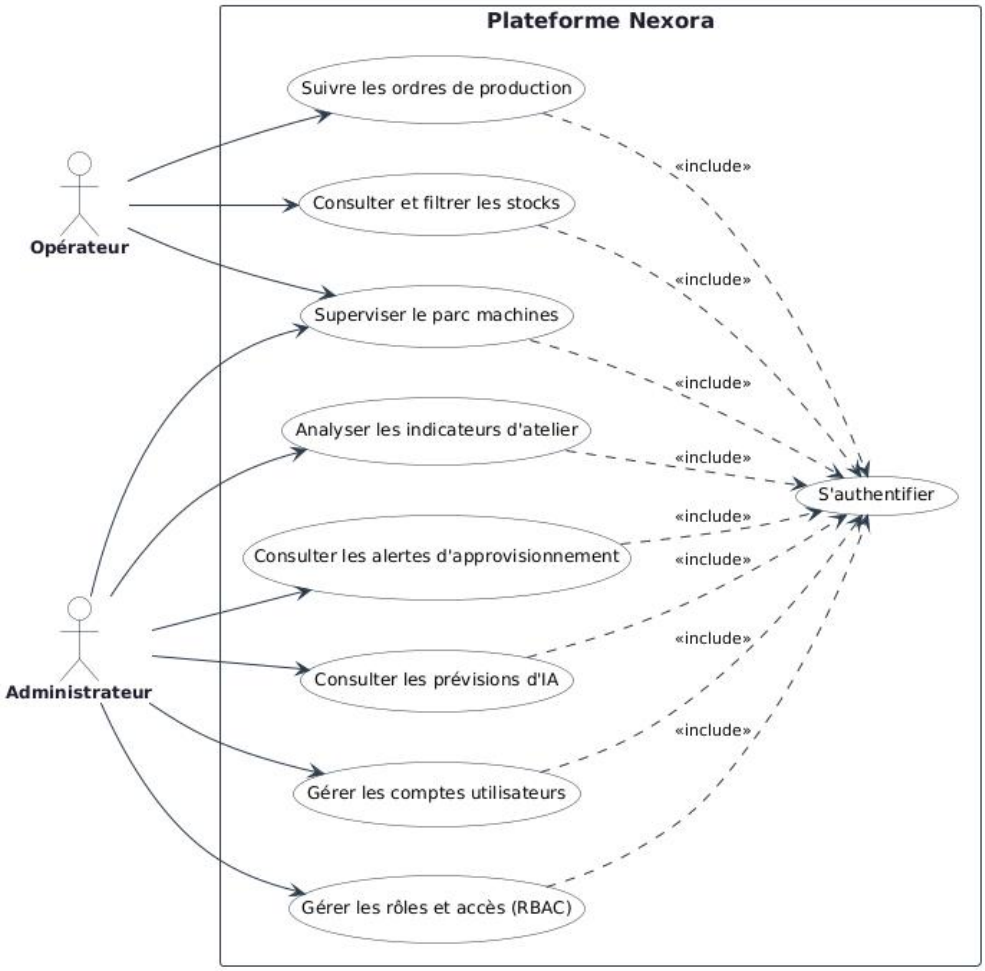


Figure 2.1 : Diagramme des cas d'utilisation global de Nexora

L'ensemble des cas d'utilisation intègre systématiquement la relation d'inclusion <<include>> avec l'opération « S'authentifier », garantissant un contrôle d'accès conforme aux privilèges de chaque acteur.

2.4 Architecture globale du système

Pour assurer la robustesse, la modularité et l'évolutivité de la solution, l'architecture globale de Nexora est structurée en quatre couches logiques, comme l'illustre la figure 2.2 :

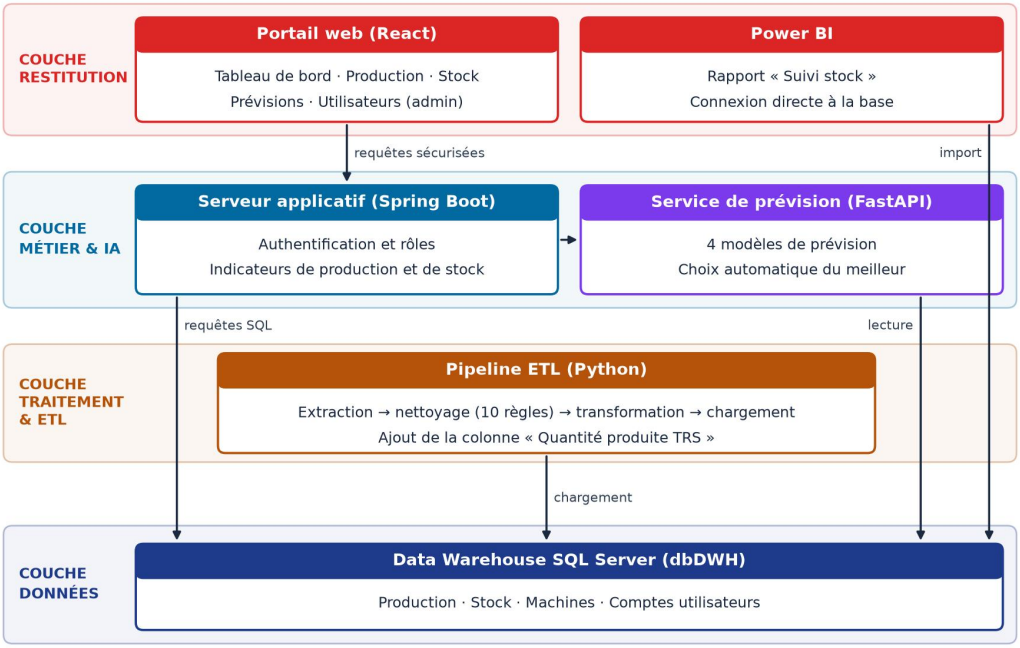


Figure 2.2 : Architecture globale du système décisionnel en quatre couches

- 1. Couche Données (Data Layer) : articulée autour de Microsoft SQL Server 2025 [16], elle héberge le Data Warehouse (base dbDWH) centralisant le référentiel des machines, les déclarations de production, les instantanés de stock ainsi que les comptes et droits d'accès de l'application. L'application lit les tables industrielles en lecture seule ; seule la table app_users est mise à jour par la gestion des comptes.
- 2. Couche Traitement & ETL (Processing Layer) : développée en Python 3 [18] avec Pandas [19] et NumPy [20], elle orchestre l'ingestion automatisée, le dédoublonnage, le traitement des anomalies qualité et la projection des données vers les tables cibles ASTOCKDATE et FACT_CLE, avec l'ajout de la colonne « Quantité produite TRS ».
- 3. Couche Métier & IA (Business & AI Layer) : regroupe les modèles de prévision (Régression Linéaire, ARIMA, Random Forest et Prophet [12], le meilleur étant sélectionné automatiquement pour chaque période) ainsi que le moteur logistique de calcul des couvertures de stock. Sur la page Prévisions, les résultats sont calculés à la demande puis mis en cache ; la page Benchmark relance à chaque ouverture l'entraînement complet des quatre modèles et affiche ses étapes en direct. Elle s'appuie sur un service Python FastAPI [21] pour les prévisions et sur un serveur Spring Boot [17] pour les règles métier et les droits d'accès.

- 4. Couche Restitution & Présentation (Presentation Layer) : un portail web réactif en React.js [22] et TypeScript [23] pour le suivi de la production, des stocks et des prévisions, complété par un rapport Microsoft Power BI [24] « Suivi stock » connecté au Data Warehouse pour l'analyse des stocks.

2.5 Environnement de travail

2.5.1 Environnement matériel

Les phases de préparation des données, d'entraînement des modèles et de développement ont été réalisées sur une station de travail présentant les caractéristiques suivantes :

- Processeur : Intel Core i7-13650HX (13e génération).
- Mémoire vive (RAM) : 12 Go.
- Stockage : Disque SSD de 512 Go.
- Système d'exploitation : Microsoft Windows 11 Professionnel (64 bits).

2.5.2 Environnement logiciel

Le tableau 2.2 présente l'ensemble des outils, langages, bibliothèques et frameworks mobilisés pour la conception et l'implémentation de Nexora :

Catégorie	Technologie / Outil	Version	Rôle et usage dans le projet
Développement	Visual Studio Code	1.142	Éditeur principal pour les scripts Python ETL/ML et le code frontend React.
Développement	IntelliJ IDEA	2026.2	Environnement de développement dédié au serveur backend Spring Boot.
Gestion de version	Git & GitHub	2.53	Gestion des versions du code source et traçabilité des livrables.
Stockage de données	Microsoft SQL Server	2025 (17.0)	Système de gestion de base de données relationnelle hébergeant le Data Warehouse [16].
Stockage de données	SQL Server Management Studio	22.3	Administration des bases et exécution des requêtes SQL de contrôle.
Langages	Python	3.14	Langage principal pour le pipeline ETL, l'ingénierie des variables et les modèles d'IA [18].
Langages	Java	17 (LTS)	Langage orienté objet pour les services backend Spring Boot.
Langages	TypeScript / JavaScript	4.7 / ES2022	Développement typé du frontend web React [23].
Services & Backend	Spring Boot	3.4.5	Serveur de l'application web : connexion, droits d'accès et lecture

Catégorie	Technologie / Outil	Version	Rôle et usage dans le projet
			des données [17].
Services & Backend	FastAPI	0.146	Service Python qui entraîne les modèles et calcule les prévisions [21].
Frontend Web	React.js	18.0	Bibliothèque d'interfaces graphiques composables pour le portail atelier [22].
Data Science & ML	Pandas & NumPy	3.0 / 2.5	Manipulation des séries tabulaires et calculs vectorisés [19, 20].
Data Science & ML	Prophet	1.5.0	Modèle de prévision : tendance, saisonnalités annuelle et hebdomadaire, jours fériés et fermetures [12].
Data Science & ML	Scikit-Learn	1.9.1	Random Forest (prévision récursive), Régression Linéaire et recherche sur grille [11].
Data Science & ML	Statsmodels	0.14.6	Modèle ARIMA et critère AIC [10].
Business Intelligence	Microsoft Power BI Desktop	2.152	Conception du rapport « Suivi stock » et des mesures DAX [24].

Tableau 2.2 : Outils, langages et bibliothèques logiciels utilisés

2.6 Conclusion

Ce chapitre a formalisé le cadre fonctionnel et technique du système Nexora issu du Sprint 0. Nous avons identifié les exigences des deux acteurs d'atelier, établi l'architecture modulaire en quatre couches et sélectionné un écosystème technologique robuste combinant SQL Server, Python, Spring Boot, FastAPI, React et Power BI. Le chapitre suivant aborde le Sprint 1, dédié au nettoyage des données et au développement du pipeline ETL.

CHAPITRE 3 : SPRINT 1 : PRÉTRAITEMENT DES DONNÉES, ASSAINISSEMENT DE LA QUALITÉ ET PIPELINE ETL

3.1 Introduction

Ce chapitre correspond au Sprint 1 de notre démarche Agile Scrum. Dans un projet d'analyse de données et d'aide à la décision, la qualité des informations en entrée conditionne directement la fiabilité des modèles prédictifs et des indicateurs de gestion. Dans un environnement industriel réel, les extractions de bases opérationnelles comportent inévitablement des anomalies de saisie, des redondances et des valeurs manquantes. L'objectif de ce premier sprint est donc d'auditer les données brutes, de concevoir un pipeline de nettoyage modulaire en Python [18], d'appliquer les règles d'assainissement et de charger les tables validées dans le Data Warehouse sous un schéma relationnel et dimensionnel.

Ce sprint réalise les récits utilisateurs US01 à US05 du Product Backlog (tableau 1.4).

3.2 Présentation des données

3.2.1 Source des données

Les données exploitées dans ce projet proviennent du système d'information industriel de l'équipementier partenaire, couvrant les usines de Kondar et Sousse en Tunisie ainsi que le site de Brno en République Tchèque. La table de production FACT_CLE couvre la période du 2 janvier 2019 au 29 mars 2026 ; la modélisation exploite l'historique récent, du 1er janvier 2024 au 26 mars 2026, soit 816 jours consécutifs (les derniers jours, dont la quantité TRS n'est pas encore consolidée, sont exclus automatiquement).

Ces sources couvrent les déclarations de fabrication, les mouvements d'inventaire physique, le référentiel des articles et le suivi du parc machines. Après prétraitement par le pipeline ETL, ces flux alimentent le Data Warehouse pour l'analyse décisionnelle et la modélisation prédictive.

Indicateur du périmètre de données	Valeur constatée	Description
Période modélisée	01/01/2024 – 26/03/2026	816 jours consécutifs (FACT_CLE disponible depuis le 02/01/2019).
Données brutes d'inventaire extraites	862 065 enregistrements	Extraction brute du stock traitée par le pipeline ETL.

Indicateur du périmètre de données	Valeur constatée	Description
Lignes d'inventaire nettoyées et validées	836 319 enregistrements	Lignes valides en sortie de l'ETL (rétention de 97,01 %).
Lignes du dernier instantané de stock	982 lignes	Stock au 28/03/2026, par article et par site.
Articles en stock	930 articles	1 589 articles distincts sur tout l'historique, 1 410 suivis sur 12 mois.
Machines du référentiel	319 machines	Table MCMachineCenter, dont 98 machines bloquées.
Déclarations de production	876 128 lignes	Table FACT_CLE (14 653 ordres de fabrication depuis 2024).

Tableau 3.1 : Périmètre quantitatif des données industrielles du projet

3.2.2 Description des tables du Data Warehouse

Le Data Warehouse Microsoft SQL Server (base dbDWH) est modélisé autour d'un schéma optimisé pour les requêtes analytiques [16], articulé autour de quatre tables réelles interconnectées couvrant la production, les stocks, le parc machines et la sécurité :

Nom de la table	Nature	Rôle et contenu fonctionnel
dbo.FACT_CLE	Table de faits	Déclarations de production (876 128 enregistrements) : ordre de fabrication, code machine, article, date de déclaration, quantité produite (Output Quantity), rebuts (Scrap Quantity), temps de marche (Run Time) et « Quantité produite TRS », variable cible des prévisions.
dbo.ASTOCKDATE	Table de faits	Instantanés de stock (814 065 enregistrements, 819 dates du 31/12/2023 au 28/03/2026) : article, description, famille (GroupeItem), quantité, valeur de la ligne (Cout), site (Kondar, Sousse, BRNO) et indicateur d'en-cours ; la baisse du stock d'un instantané au suivant sert à estimer la consommation de chaque article.
dbo.MCMachineCenter	Dimension	Référentiel des 319 machines : code (par exemple CZ1-A043 ou TN2-PHV.E60.1), désignation, centre de charge, famille de machine, site (Database), efficience nominale, capacité et indicateur de blocage.
dbo.app_users	Table système	Gestion de la sécurité et contrôle d'accès : comptes utilisateurs, hachage sécurisé des mots de passe, traçabilité et affectation des deux rôles applicatifs (Administrateur et Opérateur).

Tableau 3.2 : Structure des tables du Data Warehouse Nexora

3.2.3 Modélisation dimensionnelle et relationnelle

La figure 3.1 présente les tables du Data Warehouse exploitées par Nexora et leurs relations :

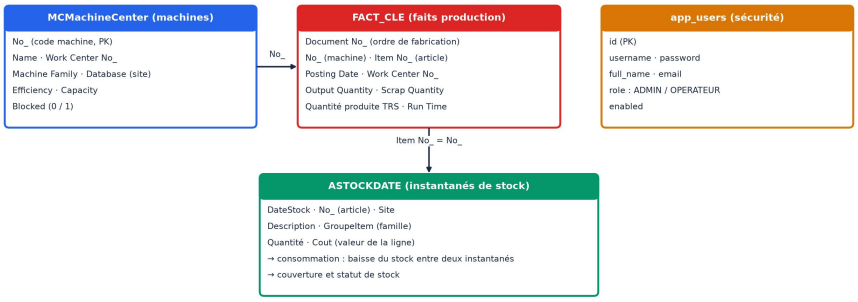


Figure 3.1 : Tables du Data Warehouse dbDWH et relations exploitées par Nexora

L'architecture des données s'articule autour des interconnexions suivantes :

- MCMachineCenter vers FACT_CLE : la dimension des machines est reliée à la table de faits de production par le code machine, ce qui permet d'associer chaque déclaration de production à sa machine, à son atelier et à son site.
- FACT_CLE et ASTOCKDATE : les deux tables partagent le code article, ce qui permet de retrouver dans les instantanés de stock l'article produit par une déclaration.
- Instantanés successifs d'ASTOCKDATE : la baisse du stock d'un instantané au suivant, sur les 365 derniers jours, donne la consommation de chaque article ; rapprochée du dernier instantané, elle permet de calculer sa couverture en jours.
- app_users : garantit l'intégrité et le cloisonnement des droits d'accès sur l'ensemble des modules d'atelier et de supervision décisionnelle.

3.3 Analyse exploratoire des données (EDA)

3.3.1 Analyse statistique de la production

Une exploration statistique descriptive a été menée sur la série journalière de production (quantité TRS de l'ensemble des machines, 816 jours du 01/01/2024 au 26/03/2026) afin d'en cerner la tendance centrale et la variabilité :

Variable (par jour)	Minimum	Maximum	Moyenne	Médiane	Écart-type	CV (%)
Quantité produite TRS (tous les jours)	0	3 175 519	230 496	255 595	149 976	65,1 %
Quantité produite TRS (jours actifs)	885	3 175 519	243 318	260 743	143 603	59,0 %
Output Quantity (jours actifs)	0	632 447	243 411	263 871	128 604	52,8 %
Rebuts – Scrap Quantity (jours actifs)	0	45 956	5 890	6 072	3 171	53,8 %

Variable (par jour)	Minimum	Maximum	Moyenne	Médiane	Écart-type	CV (%)
Temps de marche – Run Time, h (jours actifs)	10,75	9 799	791	878	503	63,5 %

Tableau 3.3 : Statistiques descriptives de la série journalière de production (01/01/2024 – 26/03/2026)

Sur la période, le taux de rebut global s'élève à 2,36 % (taux de conformité de 97,64 %) et 43 jours ne comportent aucune production. Le tableau 3.4 mesure l'effet du calendrier sur la production journalière :

Type de jour	Nb jours	Production moy. / jour	Production max / jour	Ratio vs jours ouvrés
Jours ouvrés (lundi–vendredi, hors fériés et août)	514	282 469	3 175 519	1,00
Samedis	113	199 848	323 967	0,71
Dimanches	109	63 870	296 577	0,23
Jours fériés tunisiens	39	143 138	355 079	0,51
Mois d'août (congés d'été)	62	162 490	343 183	0,58
Jours sans production	43	0	0	0,00

Tableau 3.4 : Effet du calendrier sur la production journalière

Lecture : les catégories peuvent se recouvrir (un samedi d'août compte dans deux lignes). Un dimanche représente environ 23 % d'un jour ouvré, un jour férié ou un jour d'août environ la moitié. Les fermetures se répètent chaque année du 28/12 au 04/01 et du 06/08 au 09/08 ; le système les apprend automatiquement comme fermetures récurrentes. Le maximum de 3,18 millions d'unités en un jour est une valeur aberrante, plafonnée avant l'apprentissage (chapitre 5).

3.3.2 Visualisation des séries temporelles

La figure 3.2 retrace l'évolution temporelle de la production journalière globale sur les 816 jours observés, mettant en lumière le rythme soutenu de l'atelier entrecoupé des baisses saisonnières estivales et hivernales :

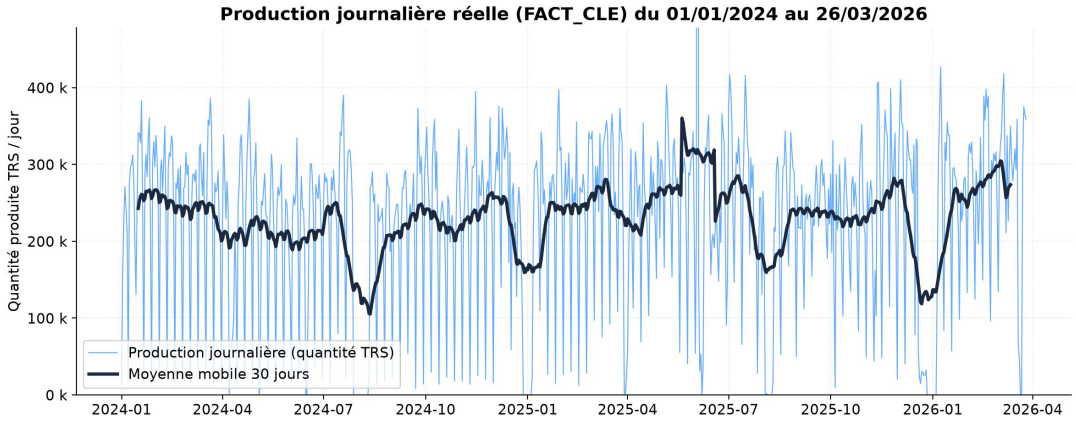


Figure 3.2 : Production journalière réelle (quantité TRS) du 01/01/2024 au 26/03/2026

La figure 3.3 présente la production moyenne selon le jour de la semaine et le mois : entre 246 000 et 292 000 unités du lundi au vendredi, 195 000 le samedi et 62 000 le dimanche ; le mois d'août (162 000) et décembre (194 000) sont nettement plus faibles.

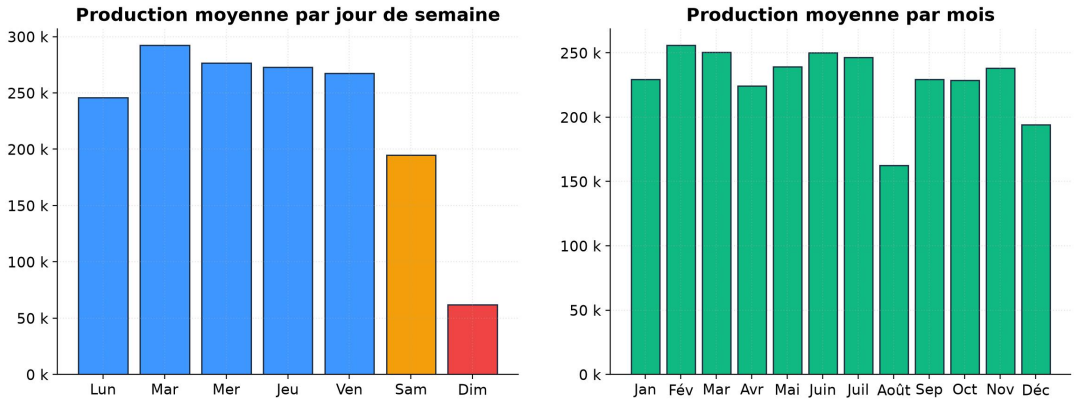


Figure 3.3 : Production moyenne par jour de semaine et par mois

La figure 3.4 illustre la carte thermique croisant mois et jours de la semaine, localisant avec précision les périodes de forte sollicitation des presses :

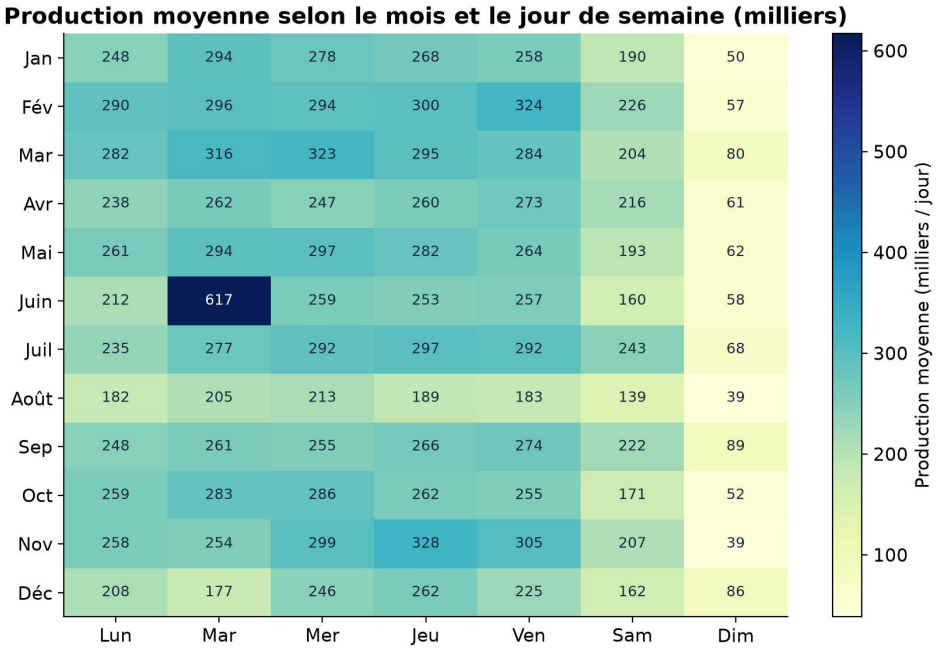


Figure 3.4 : Production moyenne selon le mois et le jour de semaine

3.4 Conception et réalisation du pipeline ETL

3.4.1 Architecture du pipeline ETL

Le pipeline de traitement, développé en Python [18, 19], est conçu de façon modulaire afin de garantir la reproductibilité et la traçabilité des transformations. Il s'articule en quatre phases séquentielles :

- 1. Ingestion : lecture des fichiers d'extraction bruts et contrôle de leur structure.
- 2. Assainissement de la qualité : application ordonnée des traitements de nettoyage décrits en section 3.4.3.
- 3. Transformation : constitution des tables ASTOCKDATE et FACT_CLE et ajout de la colonne « Quantité produite TRS » (section 3.4.4).
- 4. Chargement : export des tables nettoyées et chargement dans des tables intermédiaires de SQL Server [16], sans modifier les tables de production ; chaque étape est journalisée.

La figure 3.5 illustre le flux séquentiel des données à travers le pipeline ETL :

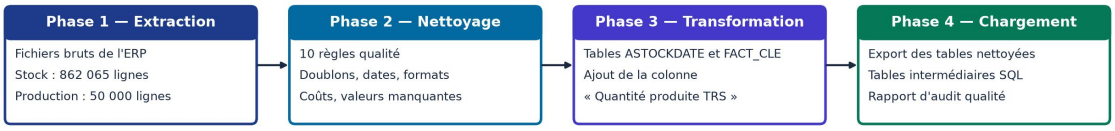


Figure 3.5 : Architecture et flux séquentiel du pipeline ETL

3.4.2 Extraction des données

Le module d'extraction extrait les données brutes issues des exports ERP sans modifier les structures initiales. Les données textuelles sont chargées sous forme brute pour permettre l'évaluation quantitative des anomalies avant toute opération de correction.

3.4.3 Transformation et traitement des anomalies

Les traitements sont présentés sur l'exécution complète du pipeline, soit 862 065 enregistrements de stock bruts. Le module de nettoyage applique dix règles qualité, regroupées ici en cinq actions :

- 1. Suppression des doublons : élimination de 22 912 lignes répétées pour une même date, un même article et un même site.
- 2. Contrôle des dates : mise au même format de toutes les dates et rejet de 1 634 lignes portant une date impossible (par exemple un 30 février).
- 3. Harmonisation des formats : uniformisation des nombres (séparateur décimal, unités écrites dans les quantités) et des libellés (familles de matière, noms de sites).
- 4. Correction des coûts unitaires : remplacement des coûts négatifs ou nuls par le coût médian de la famille de matière (115 452 coûts réajustés) et régularisation de 848 stocks négatifs transitoires.
- 5. Traitement des valeurs manquantes : rejet de 1 200 lignes sans identifiant article et imputation de 1 144 valeurs manquantes sur les champs secondaires.

Le tableau 3.5 résume la cascade de rétention mesurée sur l'extraction complète :

Étape de traitement ETL	Volume (lignes)	Variation
Volume brut extrait (stock)	862 065	100 %
Suppression des doublons	- 22 912	- 2,66 %
Rejet des dates et identifiants articles invalides (1 634 + 1 200)	- 2 834	- 0,33 %
Volume final validé (sortie du pipeline)	836 319	Rétention : 97,01 %

Tableau 3.5 : Cascade de rétention du pipeline ETL (862 065 lignes)

Sur un échantillon de 51 500 lignes, le même pipeline retient 51 096 lignes (99,22 %). La table ASTOCKDATE du Data Warehouse exploitée par l'application contient 814 065 enregistrements.

Les variables utilisées par les modèles de prévision (calendrier, jours fériés, fermetures, retards et moyennes mobiles) sont calculées par le service de prévision ; elles sont détaillées au chapitre 5.

3.4.4 Ajout de la colonne « Quantité produite TRS »

Lors de la transformation, le pipeline ajoute à la table de production FACT_CLE une colonne calculée, la « Quantité produite TRS ». Elle répond à un besoin simple : disposer, pour chaque déclaration, de la quantité de pièces bonnes réellement produites, y compris lorsque l'opérateur n'a pas saisi de quantité.

En effet, sur les 50 000 déclarations de production traitées, seules 8 724 comportent une quantité produite, alors que 11 339 enregistrent un temps de marche de la machine sans aucune quantité. Sans correction, cette production serait ignorée et les volumes seraient sous-estimés. La colonne est donc calculée selon trois cas :

$$\textit{Quantité TRS} = \textit{Output} - \textit{Rebuts, si une quantité est déclarée}$$

$$\textit{Quantité TRS} = \textit{Temps de marche} \times \textit{cadence habituelle de la machine, si seul le temps de marche est déclaré}$$

$$\textit{Quantité TRS} = 0\textit{, si la déclaration ne comporte ni quantité ni temps de marche}$$

La cadence habituelle d'une machine est la médiane de ses pièces produites par heure, calculée sur ses déclarations complètes (à défaut, la médiane de l'ensemble des machines). Sur l'extraction traitée, la part estimée représente 4,87 millions d'unités sur 31,2 millions (15,6 %). Cette colonne sert ensuite de mesure de production pour les prévisions du chapitre 5.

3.4.5 Chargement des données

La phase finale exporte les tables nettoyées puis les charge dans des tables intermédiaires (préfixe STG_) de SQL Server. Ce choix garantit que les tables de production du Data Warehouse ne sont jamais écrasées par le pipeline.

3.5 Résultats du pipeline ETL

Le tableau 3.6 synthétise les indicateurs obtenus lors de l'exécution complète du pipeline :

Indicateur de performance ETL	Valeur mesurée	Interprétation
Lignes brutes traitées en entrée	862 065 enregistrements	Extraction brute du stock.
Lignes validées en sortie	836 319 enregistrements	Lignes valides exportées vers la table cible ASTOCKDATE.
Taux de rétention des données	97,01 %	Après suppression des doublons (-2,66 %) et rejets (-0,33 %).
Identifiants et dates invalides en sortie	0	Les lignes concernées sont rejetées par le pipeline.
Corrections appliquées	1 248 326 textes · 878 088 nombres · 115 452 coûts	Harmonisation des formats et des valeurs.
Temps d'exécution du pipeline	44,5 secondes	Dont 33,8 s pour les dix règles de nettoyage.

Tableau 3.6 : Résultats quantitatifs et techniques du pipeline ETL

3.6 Bilan du Sprint 1

Le tableau 3.7 présente le bilan d'avancement des livrables réalisés au terme du Sprint 1 :

Tâche planifiée	Livrable produit	Statut
Extraction des sources brutes	Module de lecture des fichiers d'extraction	Réalisé
Nettoyage des données	Module de nettoyage en cinq actions (doublons, dates, formats, coûts, valeurs manquantes)	Réalisé
Transformation	Tables cibles ASTOCKDATE et FACT_CLE (calcul de la quantité TRS)	Réalisé
Chargement	Export et chargement dans les tables intermédiaires	Réalisé
Table de production	Nettoyage des 50 000 déclarations et ajout de la quantité TRS	Réalisé
Rapport d'audit de qualité	Journal d'exécution et bilan avant/après nettoyage	Réalisé

Tableau 3.7 : Bilan des livrables du Sprint 1

3.7 Conclusion

Ce chapitre a présenté les travaux menés lors du Sprint 1 pour fiabiliser les données industrielles. En assainissant l'extraction brute d'inventaire de 862 065 lignes pour obtenir 836 319 enregistrements validés (97,01 %), le pipeline ETL garantit une base de données cohérente et sans doublon. Ces données intègres permettent d'aborder sereinement le Sprint 2, consacré au développement du module de gestion intelligente des stocks.

CHAPITRE 4 : SPRINT 2 : DÉVELOPPEMENT DU MODULE DE GESTION INTELLIGENTE DES STOCKS

4.1 Introduction

Ce chapitre correspond au Sprint 2 de notre démarche Scrum. Dans un atelier de plasturgie automobile, la gestion proactive des stocks de matières premières (résines thermoplastiques telles que PP, PA66 ou ABS) et de sous-composants est déterminante pour prévenir les arrêts inopinés de presses tout en limitant l'immobilisation financière liée aux surstocks. L'objectif de ce sprint est de concevoir le module de gestion intelligente des stocks de la plateforme Nexora. En s'appuyant sur les données assainies issues du Data Warehouse, ce module segmente le catalogue d'articles, analyse la couverture restante, signale visuellement les articles en rupture ou critiques et calcule les réapprovisionnements optimaux pour sécuriser un horizon de 45 jours d'activité sur les 1 410 articles suivis [14, 15].

Ce sprint réalise les récits utilisateurs US06 à US11 du Product Backlog (tableau 1.4).

4.2 Architecture fonctionnelle du module de gestion des stocks

Le fonctionnement du module repose sur un enchaînement méthodique en quatre phases logistiques :

- 1. Ingestion des données d'inventaire : lecture des stocks physiques disponibles et des valorisations d'inventaire depuis la table ASTOCKDATE du Data Warehouse, dont les instantanés successifs permettent aussi d'estimer les consommations.
- 2. Calcul des indicateurs logistiques : taux de consommation journalier et couverture en jours de chaque article.
- 3. Classification opérationnelle des articles : segmentation des 1 410 articles présents dans les instantanés de stock des 12 derniers mois selon leur couverture (Rupture, Critique, Normal, Surstock, Sans consommation, Inactif), permettant un ciblage précis des urgences logistiques.
- 4. Recommandations et budgétisation : proposition de quantités de commande pour sécuriser un horizon de 45 jours calculées à partir du taux de consommation validé, calcul de l'enveloppe budgétaire et émission d'alertes.

4.3 Analyse des niveaux de stock et de la couverture

Pour évaluer la situation de chaque article, nous calculons son taux de consommation journalier à partir des baisses de stock observées d'un instantané au suivant sur les 365 derniers jours (tous sites confondus, afin que les transferts entre sites ne soient pas comptés comme des consommations) :

$$Taux_Journalier_Historique_i = Consommation_Annuelle_i / 365$$

L'indicateur fondamental de gestion [14] suivi pour chaque article est le suivant :

- La couverture disponible en jours : durée d'autonomie estimée de la production en l'absence de toute nouvelle livraison : $Couverture_Jours_i = Stock_Actuel_i / Taux_Journalier_i$

4.4 Classification opérationnelle et analyse de criticité des stocks

4.4.1 Typologie des statuts de stock et seuils d'autonomie

Dans une logique industrielle réactive et pragmatique, la plateforme Nexora privilégie une classification opérationnelle directement articulée aux contraintes de fabrication. Chacun des 1 410 articles suivis est évalué selon sa couverture en jours, ce qui le classe dans l'un des six états du tableau 4.1 [9, 14] :

Statut du stock	Condition appliquée	Indicateur visuel	Action opérationnelle recommandée
Rupture de Stock	Stock ≤ 0 et consommation au cours des 30 derniers jours	Rouge	Commande d'extrême urgence et réordonnancement pour éviter l'arrêt machine.
Stock Critique	Stock > 0 et Couverture < 15 jours	Orange	Déclenchement d'un réapprovisionnement prioritaire sous 48 heures.
Stock Normal	15 jours ≤ Couverture < 120 jours	Vert	Niveau nominal équilibré ; aucune commande immédiate requise.
Surstock	Couverture ≥ 120 jours	Violet	Gel des commandes futures pour limiter l'immobilisation de trésorerie.
Sans consommation	Stock > 0 et aucune consommation sur 12 mois	Gris	Stock dormant : vérifier l'utilité de l'article.
Inactif	Stock ≤ 0 et aucune consommation récente	Gris clair	Aucune action : article hors activité.

Tableau 4.1 : Classification des produits selon le niveau de couverture disponible

4.4.2 Répartition du catalogue et analyse de criticité

L'application de cette grille d'analyse sur l'inventaire consolidé du Data Warehouse fournit une cartographie précise de l'état des stocks d'atelier :

- Articles en situation nominale (Stock Normal) : 288 articles (20,4 %) dont la couverture est comprise entre 15 et 120 jours.
- Articles sous tension (Rupture et Critique) : 325 articles (23,0 %), dont 136 en rupture (9,6 %), avec un stock nul alors qu'ils ont été consommés au cours des 30 derniers jours, et 189 en stock critique (13,4 %), avec moins de 15 jours de couverture.
- Articles excédentaires ou dormants : 355 articles en surstock (25,2 %, couverture d'au moins 120 jours), 18 articles en stock sans aucune consommation sur 12 mois (1,3 %) et 344 articles inactifs (24,4 %).

4.5 Génération des recommandations et chiffrage budgétaire

4.5.1 Algorithme de réapprovisionnement à horizon cible de 45 jours

Pour les références en situation de Rupture ou de Stock Critique, le système calcule la quantité exacte requise pour rétablir une couverture de sécurité de 45 jours (couvrant un délai moyen d'approvisionnement fournisseur de 30 jours augmenté d'un stock de sécurité de 15 jours) :

$$Q_commander_i = max(0, \lceil Taux_Journalier_i \times 45 \rceil - max(0, Stock_Actuel_i))$$

avec :

$$Taux_Journalier_i = Consommation_Annuelle_i / 365$$

Cette formulation, directement issue du moteur logistique du système, s'appuie sur la consommation annuelle validée dans le Data Warehouse. Elle garantit un réapprovisionnement proportionné aux cadences réelles sans introduire d'instabilité artificielle liée aux incertitudes prévisionnelles. L'intégration d'une pondération dynamique par les prévisions d'apprentissage automatique constitue une perspective d'évolution modulaire.

4.5.2 Estimation du budget d'approvisionnement

Le montant financier prévisionnel des réapprovisionnements est obtenu en valorisant les quantités suggérées par le coût unitaire d'achat réel enregistré dans le Data Warehouse :

$$Budget_Total = \Sigma\ (Q_commander_i \times Prix_Unitaire_i) \text{ pour l'ensemble des références } i \in (Rupture \cup Critique)$$

Cette métrique offre à l'administrateur une visibilité consolidée sur les engagements de trésorerie nécessaires à la continuité de la production.

4.5.3 Hiérarchisation des alertes d'atelier

La page Stock permet de filtrer les articles par statut (Rupture, Critique…) et de trier la liste par couverture en jours, afin que l'administrateur et l'opérateur traitent en priorité les articles les plus urgents ; les quantités des articles en rupture ou critiques sont affichées en rouge.

4.6 Résultats obtenus

L'analyse est conduite sur les 1 410 articles présents dans les instantanés de stock des 12 derniers mois, à la date du dernier instantané (28/03/2026).

Sur ces 1 410 articles, la distribution opérationnelle des stocks issue du Data Warehouse s'établit ainsi :

- Stock Normal : 368 articles (26,1 %) disposent d'une couverture comprise entre 15 et 120 jours.
- Rupture de Stock : 136 articles (9,6 %) ont un stock nul alors qu'ils ont été consommés au cours des 30 derniers jours.
- Stock Critique : 189 articles (13,4 %) présentent une couverture strictement inférieure à 15 jours.
- Surstock : 355 articles (25,2 %) dépassent 120 jours de couverture.
- Sans consommation : 18 articles (1,3 %) sont en stock sans aucune baisse de stock sur 12 mois (stock dormant).
- Inactif : 344 articles (24,4 %) n'ont ni stock ni consommation récente.

La figure 4.1 illustre la répartition des articles suivis selon les six statuts :

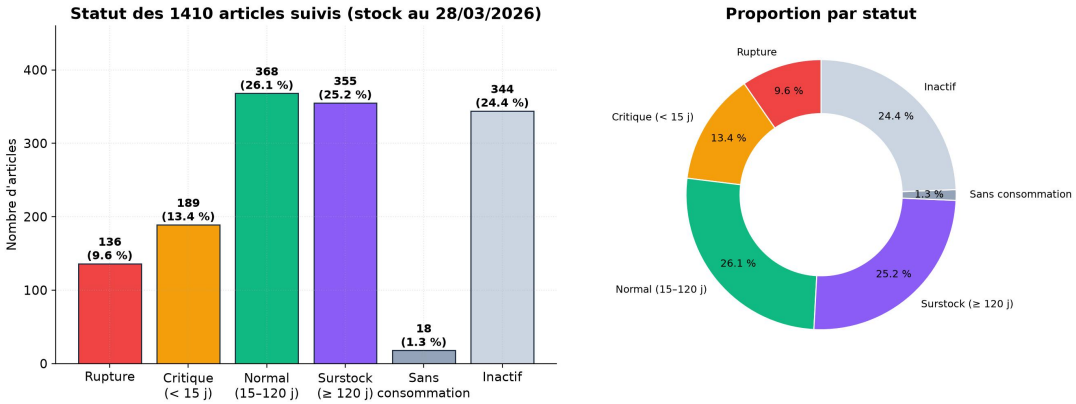


Figure 4.1 : Répartition des 1 410 articles suivis par statut de stock

La figure 4.2 présente les articles en alerte par famille (champ GroupeItem) : la famille PF-PSF (produits finis et semi-finis) concentre 264 des 325 alertes (123 ruptures et 141 critiques), devant Emballage (26), Insert (26), Matière (7) et Consommable (2).

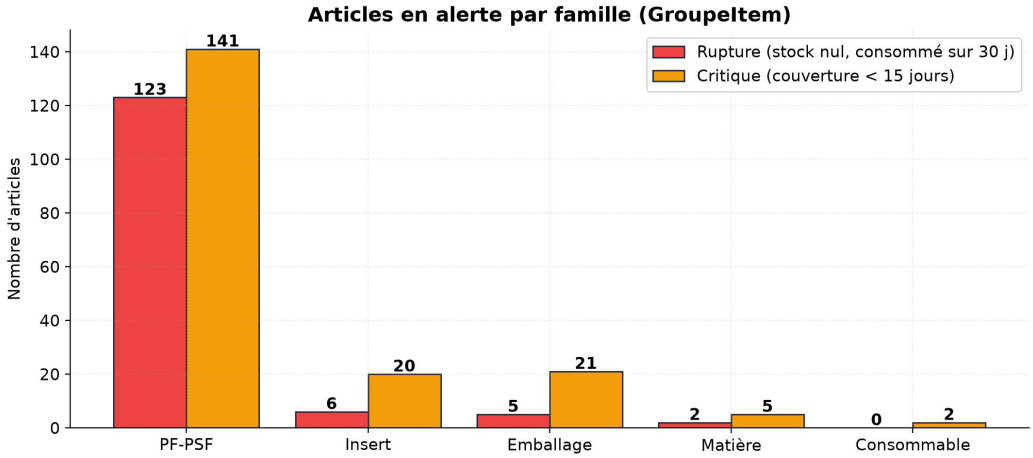


Figure 4.2 : Articles en rupture et en stock critique par famille (GroupeItem)

Au total, le plan de réapprovisionnement à 45 jours concerne 325 articles (136 en rupture et 189 critiques). La quantité globale à commander s'élève à 3 671 804 unités, pour un budget prévisionnel de 1 095 585 TND, calculé d'après les coûts unitaires réels du Data Warehouse (coût moyen pondéré de 0,298 TND par unité ; aucun article concerné n'est sans coût connu).

Précision sur les granularités d'analyse : le statut est calculé par article, tous sites confondus. La page Stock de l'application affiche les 982 lignes du dernier instantané

(article × site) avec leur couverture et leur statut, et le rapport Power BI présente la valeur du stock par site, par famille et par article.

4.7 Bilan du Sprint 2

Le tableau 4.2 dresse le bilan des livrables réalisés au terme du Sprint 2 :

Tâche planifiée	Livrable produit	Statut
Architecture du module	Schéma fonctionnel des flux et indicateurs de gestion des stocks	Réalisé
Calcul des indicateurs	Calcul automatisé des taux journaliers et de la couverture en jours	Réalisé
Classification opérationnelle	Répartition des références du catalogue en états de criticité	Réalisé
Classification par statut	Hiérarchisation visuelle selon les statuts opérationnels de stock	Réalisé
Algorithme de réapprovisionnement	Formule de calcul des besoins basée sur la consommation d'atelier	Réalisé
Chiffrage budgétaire	Calcul de l'enveloppe budgétaire des approvisionnements prioritaires	Réalisé
Alertes et exports	Filtres par statut, tri par couverture et export Excel du stock	Réalisé

Tableau 4.2 : Bilan des livrables du Sprint 2

4.8 Conclusion

Ce chapitre a détaillé le développement du module de gestion intelligente des stocks lors du Sprint 2. En associant une classification opérationnelle en six statuts selon l'autonomie réelle et une formule de réapprovisionnement sur 45 jours basée sur la consommation d'atelier validée, la plateforme Nexora remplace les pratiques manuelles par un pilotage dynamique et préventif unifié sur les 1 410 articles suivis. Le chapitre suivant aborde le Sprint 3, consacré à la modélisation prédictive par Intelligence Artificielle et aux prévisions de cadence.

CHAPITRE 5 : SPRINT 3 : MODÉLISATION PRÉDICTIVE PAR INTELLIGENCE ARTIFICIELLE

5.1 Introduction

Ce chapitre correspond au Sprint 3 de notre démarche Scrum, consacré au développement du moteur prédictif et analytique de la plateforme Nexora. Pour anticiper les charges des ateliers d'injection et prévenir les tensions sur les approvisionnements, quatre algorithmes d'apprentissage automatique ont été développés et comparés : la Régression Linéaire, un modèle autorégressif ARIMA, Random Forest et le modèle Prophet.

La validation croisée temporelle montre que les quatre modèles obtiennent des erreurs proches sur l'historique récent (erreur moyenne de 67 927 à 75 122 unités par jour sur 12 plis de 30 jours), ce qui reflète la forte variabilité journalière de la production. Le choix du modèle n'est donc pas figé : pour chaque mois à prévoir, la plateforme retient automatiquement le modèle le plus précis sur le même mois de l'année précédente. Pour mai 2026, il s'agit de Random Forest.

Ce sprint réalise les récits utilisateurs US12 à US16 du Product Backlog (tableau 1.4).

5.2 Démarche méthodologique de modélisation prédictive

Le processus de modélisation prédictive des cadences de production d'atelier s'articule autour de cinq étapes méthodologiques :

- 1. Extraction des données d'atelier : lecture de l'historique des déclarations de fabrication depuis la table FACT_CLE du Data Warehouse (816 jours, du 01/01/2024 au 26/03/2026).
- 2. Ingénierie des variables : calendrier, jours fériés tunisiens, fermetures récurrentes, décalages temporels et moyennes mobiles.
- 3. Entraînement des modèles : ajustement des algorithmes sur l'historique de production d'injection plastique.
- 4. Évaluation et sélection : validation croisée temporelle (MAE, RMSE, R^2), réglage des hyperparamètres et sélection du meilleur modèle sur le même mois de l'année précédente.

- 5. Restitution : exposition des prévisions par l'API FastAPI, mise en cache et affichage dans les pages Data Science et Benchmark du portail web, avec comparaison à la production réelle de l'année précédente.

5.3 Préparation des données et variables explicatives

5.3.1 Variable cible et préparation de la série

La variable cible est la quantité produite TRS journalière de l'ensemble des machines (somme du champ « Quantité produite TRS » de FACT_CLE par date de déclaration) ; les jours sans déclaration valent zéro. Avant chaque entraînement, les valeurs extrêmes sont plafonnées par la règle de Tukey, calculée sur les seules données d'entraînement :

$$y_t \leftarrow min(y_t,\ Q3 + 3 \times (Q3 - Q1))$$

Ce plafonnement neutralise les journées aberrantes (jusqu'à 3,18 millions d'unités en un jour, pour une médiane de 255 595) sans supprimer de dates. Les derniers jours de l'historique sont exclus tant que leur quantité TRS n'est pas consolidée (TRS inférieure à 50 % de l'Output Quantity). Aucune transformation logarithmique n'est appliquée : prévisions et erreurs sont exprimées directement en unités par jour.

5.3.2 Variables explicatives et calendrier industriel

Le tableau 5.1 récapitule les variables utilisées par chaque modèle :

Modèle	Variables utilisées	Justification
Random Forest (10)	jour de la semaine, mois, jour férié, fermeture ; production des jours précédents (veille, semaine et mois précédents) ; moyennes sur 7 et 28 jours	Prévision récursive : chaque jour prévu alimente les retards du jour suivant.
Régression linéaire simple (1)	le temps (numéro du jour)	Modèle de référence le plus simple : une droite de tendance.
Prophet	tendance, saisonnalités annuelle et hebdomadaire, événements « jour férié TN » et « fermeture usine »	Décomposition additive avec calendrier d'événements.
ARIMA	la production des sept jours précédents (ordre p = 7)	Modèle statistique univarié de référence.

Tableau 5.1 : Variables utilisées par chaque modèle

Le calendrier industriel combine les jours fériés tunisiens et les fermetures récurrentes apprises automatiquement : une date est une fermeture lorsqu'elle appartient à une suite d'au moins 3 jours sans production observée au moins deux années différentes (sur

l'historique : du 28/12 au 04/01 et du 06/08 au 09/08). Les prévisions de ces jours sont fixées à zéro.

5.3.3 Validation croisée temporelle (origine glissante)

Une validation croisée classique (k-fold aléatoire) entraînerait les modèles sur le futur pour prédire le passé. Nous utilisons donc une validation croisée à origine glissante : à chaque pli, le modèle est entraîné uniquement sur les jours antérieurs à la date de coupure, puis évalué sur les 30 jours suivants (tableau 5.2) :

Étape	Données utilisées	Nombre de jours	Rôle méthodologique
Validation croisée (12 plis)	12 coupures successives ; tests du 01/04/2025 au 26/03/2026	12 × 30 jours	Erreur moyenne des modèles (MAE, RMSE, R^2).
Réglage des hyperparamètres	données antérieures au 01/05/2025, 6 plis	6 × 30 jours	Choix des hyperparamètres de chaque modèle (option).
Validation N-1 (sélection)	entraînement jusqu'au 30/04/2025, test du 01/05 au 31/05/2025	31 jours	Choix du meilleur modèle pour la prévision de mai 2026.

Tableau 5.2 : Protocole de validation temporelle

À chaque pli, les modèles sont réentraînés depuis zéro et la préparation (plafonnement, fermetures) est recalculée sur les seules données d'entraînement, ce qui évite toute fuite d'information du futur vers le passé (data leakage). La validation croisée représente ainsi 48 entraînements (4 modèles × 12 plis), avec au moins 60 jours d'historique par entraînement.

5.4 Métriques d'évaluation de la performance

La qualité des prévisions est mesurée par trois indicateurs simples [4] :

- MAE (Mean Absolute Error) : écart absolu moyen entre production réelle et prévue, en unités par jour ; c'est le critère de choix du modèle :
  $MAE = (1 / n) \times \Sigma |y_i - \hat{y}_i|$
- RMSE (Root Mean Squared Error) : racine de l'erreur quadratique moyenne, pénalisant fortement les grands écarts : $RMSE = \sqrt{((1 / n) \times \Sigma (y_i - \hat{y}_i)^2)}$
- R^2 (Coefficient de détermination) : proportion de la variance de cadence expliquée par le modèle : $R^2 = 1 - (\Sigma (y_i - \hat{y}_i)^2 / \Sigma (y_i - \bar{y})^2)$

5.5 Développement des modèles d'intelligence artificielle

Pour modéliser la cadence de production de l'atelier d'injection plastique et anticiper les charges machines, quatre approches algorithmiques [5] ont été développées, entraînées et comparées :

5.5.1 Régression Linéaire Simple

La régression linéaire simple sert de modèle de référence (baseline). Elle explique la production journalière par une seule variable, le temps (numéro du jour), et trace ainsi une droite de tendance ; estimée par moindres carrés ordinaires, elle n'a pas d'hyperparamètre :

$$y = a + b \times t + \varepsilon$$

où a est la constante (niveau de départ), b la pente (variation moyenne de la production d'un jour à l'autre), t le numéro du jour et ε le terme d'erreur résiduelle.

Avantages	Limites
Temps d'apprentissage et d'inférence quasi-instantanés.	Incapacité structurelle à modéliser les non-linéarités complexes d'atelier.
Interprétation directe : une constante et une pente.	Ne capte pas les ruptures de niveau de la production.
Faible consommation de ressources de calcul.	Ne capte ni le rythme hebdomadaire ni les fermetures (une seule variable, le temps).

TABLEAU 5.3 : Avantages et limites : Régression Linéaire Simple

5.5.2 Modèle ARIMA

Le modèle ARIMA [3] constitue la méthode statistique univariée de référence pour les séries temporelles. Il combine la dépendance linéaire aux valeurs passées de la série (partie autorégressive AR d'ordre p), une différenciation d'ordre d pour assurer la stationnarité, et l'influence des chocs aléatoires passés (partie moyenne mobile MA d'ordre q) :

$$y'_t = c + \Sigma\,(\phi_i \times y'_{t-i}) + \Sigma\,(\theta_j \times \varepsilon_{t-j}) + \varepsilon_t$$

où y'_t est la série différenciée d fois, ϕ_i les paramètres autorégressifs, θ_j les paramètres de moyenne mobile, et ε_t un bruit blanc gaussien.

Nexora utilise un modèle ARIMA(7, 0, 1) avec constante, sans composante saisonnière : l'ordre autorégressif p = 7 relie la production d'un jour à celle des sept jours précédents, dont le même jour de la semaine précédente.

Avantages	Limites
Méthode statistique de référence, simple à interpréter.	Difficulté à intégrer simultanément plusieurs cycles saisonniers sans réajustement permanent.
Bonne réactivité sur les profils cycliques réguliers.	Sensible aux ruptures calendaires abruptes et arrêts de production non programmés.
Paramétrisation formelle et rigoureuse (p, d, q).	Ne prend pas en compte nativement les variables exogènes d'atelier.

TABLEAU 5.4 : Avantages et limites : Modèle ARIMA

5.5.3 Modèle Random Forest Regressor

Random Forest [6], [7] est un algorithme d'apprentissage automatique supervisé par ensemble (ensemble learning). Il construit une forêt de B arbres de décision indépendants entraînés chacun sur un tirage aléatoire des données et des variables. La prédiction finale résulte de la moyenne des prédictions individuelles :

$$\hat{y} = (1 / B) \times \Sigma\, T_b(x)$$

Cette approche par agrégation réduit considérablement la variance sans dégrader le biais, permettant de capturer les interactions non linéaires complexes propres aux cadences d'atelier. Dans Nexora, la forêt (200 arbres, profondeur maximale 12) prévoit la production d'un jour à partir des 10 variables du tableau 5.1 ; la prévision du mois est récursive, chaque valeur prévue servant de retard pour le jour suivant.

Avantages	Limites
Capte les relations non-linéaires complexes	Modèle boîte noire (interprétabilité réduite)
Robuste aux valeurs aberrantes (outliers)	Temps de calcul et empreinte mémoire plus élevés
Peu sensible au surapprentissage grâce à la moyenne de nombreux arbres	Ne peut pas extrapoler au-delà des valeurs observées

TABLEAU 5.5 : Avantages et limites : Random Forest

5.5.4 Modèle Prophet (Meta)

Développé par Meta, Prophet [12] est un modèle additif modulaire conçu pour les séries temporelles industrielles présentant de fortes saisonnalités et des variations calendaires. La cadence journalière est décomposée selon quatre composantes structurelles :

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

où g(t) modélise la tendance générale non linéaire avec détection automatique des points de rupture (changepoints), s(t) représente les variations périodiques hebdomadaires via

des séries de Fourier, h(t) quantifie l'impact des événements d'atelier (jours fériés tunisiens et fermetures d'usine apprises), et ε_t est le résidu d'erreur normale.

Avantages	Limites
Décomposition explicable (tendance, saisonnalités, événements).	Tendance pouvant dériver en fin de série (points de rupture).
Calendrier d'événements natif (jours fériés, fermetures).	Sensible aux ruptures structurelles non identifiées comme points de changement.
Entraînement rapide (quelques secondes), adapté au réentraînement à chaque requête.	
Saisonnalités annuelle et hebdomadaire modélisées par séries de Fourier.	

TABLEAU 5.6 : Avantages et limites : Prophet

5.6 Réglage des hyperparamètres

Chaque modèle possède quelques réglages, appelés hyperparamètres (par exemple le nombre d'arbres pour Random Forest). Pour chacun, nous avons testé plusieurs valeurs et retenu celles qui donnent la plus petite erreur en validation croisée ; pour ARIMA, le choix se fait avec le critère AIC. Ce test n'utilise que les données antérieures à mai 2025, afin de garder la période de validation N-1 intacte :

Modèle	Réglages testés	Valeur par défaut	Valeur retenue	Erreur en validation croisée (unités/j)
Random Forest	Nombre d'arbres, profondeur des arbres, taille des feuilles	200 arbres, profondeur 12	200 arbres, profondeur 6	48 891 → 48 027
Prophet	Souplesse de la tendance, type de saisonnalité	Souplesse 0,05	Souplesse 0,05	66 969 → 66 969
ARIMA	Ordres (p, d, q) : (7, 0, 0), (7, 0, 1), (7, 1, 1)	(7, 0, 1)	(7, 1, 1)	Choix par le critère AIC
Régression linéaire simple	Aucun réglage nécessaire	—	—	—

Tableau 5.7 : Réglages testés et résultats

Le réglage réduit légèrement l'erreur en validation croisée, mais cet écart reste du même ordre que la variabilité de la production. Sur la période de validation N-1 (mai 2025), il ne profite qu'à ARIMA (tableau 5.8) :

Modèle	MAE mai 2025 (valeurs par défaut)	MAE mai 2025 (valeurs réglées)	Écart

Modèle	MAE mai 2025 (valeurs par défaut)	MAE mai 2025 (valeurs réglées)	Écart
Random Forest	33 614 u/j	33 697 u/j	+83 u/j
Prophet	65 937 u/j	65 937 u/j	0 (aucun changement)
ARIMA	60 583 u/j	50 211 u/j	−10 372 u/j
Régression linéaire simple	79 908 u/j	79 908 u/j	0 (aucun réglage)

Tableau 5.8 : Effet du réglage sur la validation N-1 (mai 2025)

Pour Random Forest, le réglage s'ajuste aux mois de la validation croisée sans mieux généraliser ; pour ARIMA, l'ordre (7, 1, 1) retenu par l'AIC réduit l'erreur de mai 2025 sans atteindre celle de Random Forest. Les hyperparamètres par défaut sont conservés en production ; le réglage reste disponible dans l'application et pourra être réactivé lorsque l'historique sera plus long.

5.7 Résultats comparatifs et sélection du modèle

Les quatre modèles ont été évalués avec leurs hyperparamètres par défaut. Le tableau 5.9 présente les erreurs de la validation croisée (12 plis de 30 jours) et l'erreur moyenne sur le même mois de l'année précédente (mai 2025), critère de sélection pour la prévision de mai 2026 :

Modèle	MAE CV (u/j)	RMSE CV (u/j)	R^2 (CV)	MAE mai 2025 (u/j)
Random Forest (retenu)	69 532	173 423	0,136	33 614
ARIMA	85 080	183 066	0,038	60 583
Prophet	67 927	169 147	0,178	65 937
Régression linéaire simple	94 635	187 422	−0,009	79 908

Tableau 5.9 : Performances des modèles (validation croisée et mai 2025)

En validation croisée, Prophet et Random Forest sont les plus précis (erreur moyenne de 67 927 et 69 532 unités par jour) ; ARIMA (85 080) et la régression linéaire simple (94 635), plus simples, sont moins précis. Le R^2 faible s'explique par quelques journées extrêmes qui dominent la variance. Sur mai 2025, Random Forest se détache nettement (33 614 unités par jour contre 60 583 pour ARIMA, 65 937 pour Prophet et 79 908 pour la régression linéaire simple) : il est retenu pour la prévision de mai 2026.

Le meilleur modèle change selon le mois. Appliquée à chacun des douze mois de 2026 (erreur mesurée sur le même mois de 2025), la règle de sélection retient Random Forest 6 mois (janvier à mai et octobre), Prophet 5 mois (juin, juillet, août, novembre et décembre,

marqués par des fermetures ou des baisses d'activité) et la régression linéaire simple 1 mois (septembre). Random Forest reste le modèle le plus régulier.

La figure 5.1 illustre le contrôle sur données réelles : la plateforme prévoit février 2026 avec les seules données disponibles au 31/01/2026, puis compare la prévision à la production effectivement réalisée :

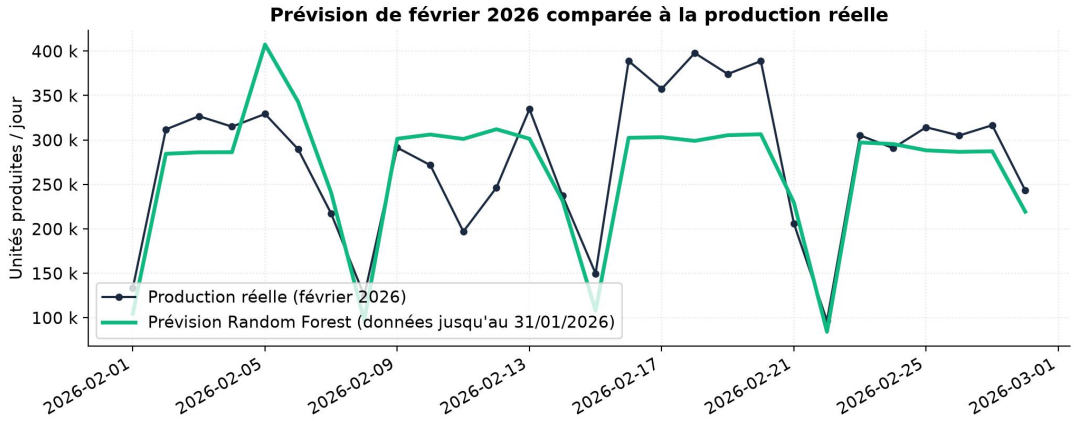


Figure 5.1 : Prévision de février 2026 (Random Forest) et production réelle

La prévision suit le rythme hebdomadaire (creux des dimanches). Sur le mois, la production prévue (7,41 millions d'unités) est proche de la production réelle (7,76 millions), soit un écart de −4,5 % ; l'erreur moyenne journalière est de 40 755 unités et le R^2 atteint 0,63.

5.8 Prévision opérationnelle et comparaison avec l'année précédente

Les pages Data Science et Benchmark présentent la prévision du meilleur modèle pour le mois choisi (par défaut mai 2026) ou pour les 30 jours qui suivent les dernières données. Chaque jour prévu est comparé à la production réelle du même jour de la semaine de l'année précédente (date − 52 semaines), afin de comparer un lundi à un lundi :

$$\text{Écart}(t) = \hat{y}(t) - y(t - 364 \text{ jours})$$

La figure 5.2 superpose la prévision de mai 2026 (Random Forest) et la production de mai 2025. La prévision totale s'élève à 7 595 764 unités, contre 8 150 549 unités produites sur les mêmes jours de semaine de mai 2025 (−6,8 %).

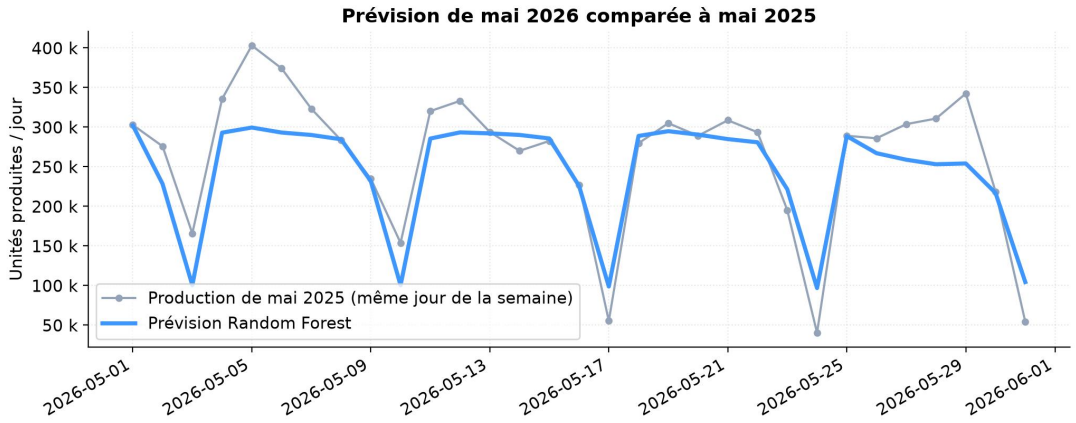


Figure 5.2 : Prévision de mai 2026 et production de mai 2025 (J − 52 semaines)

Pour un mois déjà écoulé, la prévision est calculée avec les seules données antérieures au mois puis comparée à la production réelle (figure 5.1). L'utilisateur peut aussi importer un fichier Excel (date, quantité) depuis la page Benchmark : les quatre modèles sont alors évalués sur ces données selon le même protocole.

Le calcul complet (validation croisée, validation N-1 et prévision) prend une à deux minutes ; le résultat est conservé en cache pendant une heure. Si un modèle ne peut pas être entraîné, il est écarté de la comparaison sans bloquer les autres.

5.9 Limites et robustesse des prévisions

La forte variabilité de la production journalière (coefficient de variation de 65 %, journées extrêmes, 43 jours sans production) limite la précision atteignable sur un mois. Le protocole en tient compte : plafonnement des valeurs extrêmes, fermetures apprises automatiquement, choix du modèle propre à chaque période et comparaison systématique avec l'année précédente. Le classement des modèles peut changer d'une période à l'autre ; c'est pourquoi la sélection est recalculée pour chaque prévision au lieu d'être fixée une fois pour toutes.

5.10 Rôles respectifs des modèles dans la plateforme Nexora

Les quatre modèles sont conservés et réévalués à chaque prévision. Random Forest est le plus régulier : il est retenu pour mai 2026 et obtient la plus faible erreur moyenne sur les douze mois de 2025 comme sur les données réelles de début 2026. Prophet obtient la meilleure erreur en validation croisée et l'emporte sur les mois marqués par des

fermetures. La régression linéaire simple et ARIMA servent de modèles de référence ; seule la régression linéaire simple l'emporte ponctuellement (septembre). Ce fonctionnement évite de figer un modèle « champion » dont la supériorité ne serait pas stable dans le temps.

5.11 Bilan du Sprint 3

Le tableau 5.10 récapitule les livrables réalisés au terme du Sprint 3 :

Tâche planifiée	Livrable produit	Statut
Préparation des variables	Série journalière TRS, plafonnement des valeurs extrêmes et calendrier industriel	Réalisé
Développement des modèles	Régression linéaire, ARIMA, Random Forest et Prophet	Réalisé
Validation croisée	Origine glissante, 12 plis de 30 jours (MAE, RMSE, R^2)	Réalisé
Réglage des hyperparamètres	Recherche sur grille (6 plis / AIC) et contrôle sur l'année N-1	Réalisé
Sélection du modèle	Plus faible MAE sur le même mois de l'année N-1	Réalisé
Déploiement opérationnel	API FastAPI, cache, choix du mois et pages Data Science / Benchmark	Réalisé

Tableau 5.10 : Bilan des livrables du Sprint 3

5.12 Conclusion

Ce chapitre a présenté le développement et l'évaluation de quatre modèles de prévision selon un protocole adapté aux séries temporelles : validation croisée à origine glissante (12 plis de 30 jours), réglage des hyperparamètres et sélection du modèle sur le même mois de l'année précédente, avec la MAE comme critère. Aucun modèle n'est le meilleur pour tous les mois : Random Forest est retenu pour mai 2026 et se montre le plus régulier, Prophet est le plus performant sur les mois de fermeture. Contrôlée sur février 2026, la prévision s'écarte de −4,5 % de la production réelle. Le chapitre suivant aborde le Sprint 4, consacré au portail web, au rapport Power BI et à la recette fonctionnelle.

CHAPITRE 6 : SPRINT 4 : DÉVELOPPEMENT DU TABLEAU DE BORD DÉCISIONNEL ET VALIDATION

6.1 Introduction

Ce chapitre correspond au Sprint 4, dernière phase de réalisation de notre projet. Après le pipeline ETL (Sprint 1), le module de gestion des stocks (Sprint 2) et les modèles de prévision (Sprint 3), ce sprint intègre l'ensemble de ces briques dans une solution de restitution. Le portail web opérationnel, développé en React.js [22] et Spring Boot [17], restitue les indicateurs de production, de stock et de prévision calculés directement sur le Data Warehouse. En complément, un rapport Microsoft Power BI [24] « Suivi stock », connecté au Data Warehouse, permet d'analyser l'évolution et la répartition des stocks par site, famille et article.

Ce sprint réalise les récits utilisateurs US17 à US21 du Product Backlog (tableau 1.4).

6.2 Architecture du tableau de bord et intégration applicative

La figure 6.1 présente l'architecture globale d'intégration et de déploiement de la solution décisionnelle Nexora :

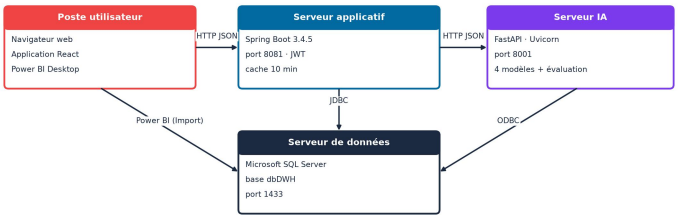


Figure 6.1 : Architecture globale d'intégration et de déploiement de Nexora

- 1. Entrepôt de données SQL Server : centralise les tables de faits (FACT_CLE, ASTOCKDATE) et le référentiel des machines ; l'application lit ces tables en lecture seule et ne modifie que la table app_users (gestion des comptes).
- 2. Backend applicatif d'entreprise (Spring Boot / FastAPI) : le serveur Spring Boot [17] gère la connexion des utilisateurs et leurs droits (administrateur ou opérateur), tandis que le service Python FastAPI [21] calcule les prévisions.
- 3. Rapport Microsoft Power BI : rapport « Suivi stock » connecté au Data Warehouse, avec des mesures DAX (coût, coût moyen, mois précédent) et des filtres par site, famille et date.

- 4. Portail web réactif React.js : interface permettant de consulter le stock du dernier instantané, d'analyser les indicateurs de production, de suivre les prévisions et d'exporter les données vers Excel.

6.3 Portail web et rapport Power BI

6.3.1 Tableau de bord principal et suivi de la production

La page Tableau de bord présente les indicateurs clés calculés sur le Data Warehouse pour la période choisie (Mois, Année ou Tout l'historique) :

- Indicateurs de production : volume produit, ordres de fabrication déclarés, rebuts et taux de conformité ; pour mars 2026 (du 01/03 au 29/03) : 7 392 572 unités, 643 ordres et 98,34 % de conformité.
- Parc machines : 319 machines du référentiel, dont 98 bloquées, et nombre de machines actives sur la période (122 en mars 2026) ; la page Machines détaille la production et la dernière déclaration de chaque machine.
- Stock : valeur du dernier instantané (2,24 M TND au 28/03/2026 pour 930 articles), répartition par famille et par site ; la page Production liste les dernières déclarations d'ordres de fabrication.

6.3.2 Pages de prévision (Data Science et Benchmark)

Ces pages, réservées à l'administrateur, s'appuient sur le service de prévision :

- Prévision du mois : le mois est choisi dans une liste (par défaut mai 2026) ; la prévision journalière du meilleur modèle (Random Forest pour mai 2026) est affichée sous forme de courbe et de tableau exportable.
- Comparaison réel / prévu : chaque jour prévu est rapproché de la production du même jour de la semaine de l'année précédente ; pour un mois déjà écoulé, la prévision est aussi comparée à la production réelle du mois.
- Indicateurs de fiabilité : erreur moyenne (MAE) sur le même mois de l'année précédente et en validation croisée, RMSE et R^2 ; la page Benchmark permet aussi d'importer un fichier Excel pour évaluer les modèles sur d'autres données.

6.3.3 Page Stock et rapport Power BI « Suivi stock »

La page Stock détaille les 982 lignes du dernier instantané (article × site) avec la couverture en jours et le statut de chaque article :

- Synthèse : valeur et quantité totales du stock, nombre d'articles par statut et plan de réapprovisionnement à 45 jours (325 articles, 3 671 804 unités, 1 095 585 TND).
- Filtres et export : recherche par article, filtres par famille, site et statut, et export Excel du stock filtré.
- Rapport Power BI « Suivi stock » : sept pages (Vue globale, Historique de stock, Stock par famille, Top 10 article, Détail stock, Analyse par article, ParetoGroupe) filtrables par site, famille et date.

6.4 Présentation du rapport Power BI « Suivi stock »

6.4.1 Valeur du stock par famille

La figure 6.2 présente l'évolution de la valeur du stock en fin de mois par famille d'articles (GroupeItem), de décembre 2023 à février 2026 ; la Matière, les Inserts et les PF-PSF représentent l'essentiel de la valeur :

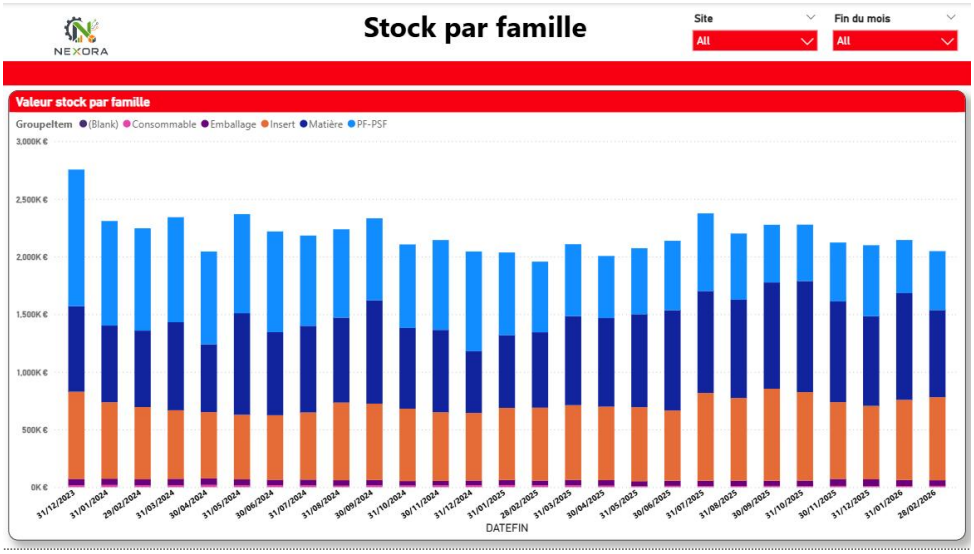


Figure 6.2 : Rapport Power BI « Suivi stock » – page Stock par famille

6.4.2 Historique et répartition des stocks d'atelier

La figure 6.3 montre l'historique de la valeur du stock en fin de mois pour chaque site (Kondar, Brno, Sousse) et pour MIT, qui consolide les trois sites ; les filtres Famille, GroupeClient et Fin du mois permettent d'affiner l'analyse :

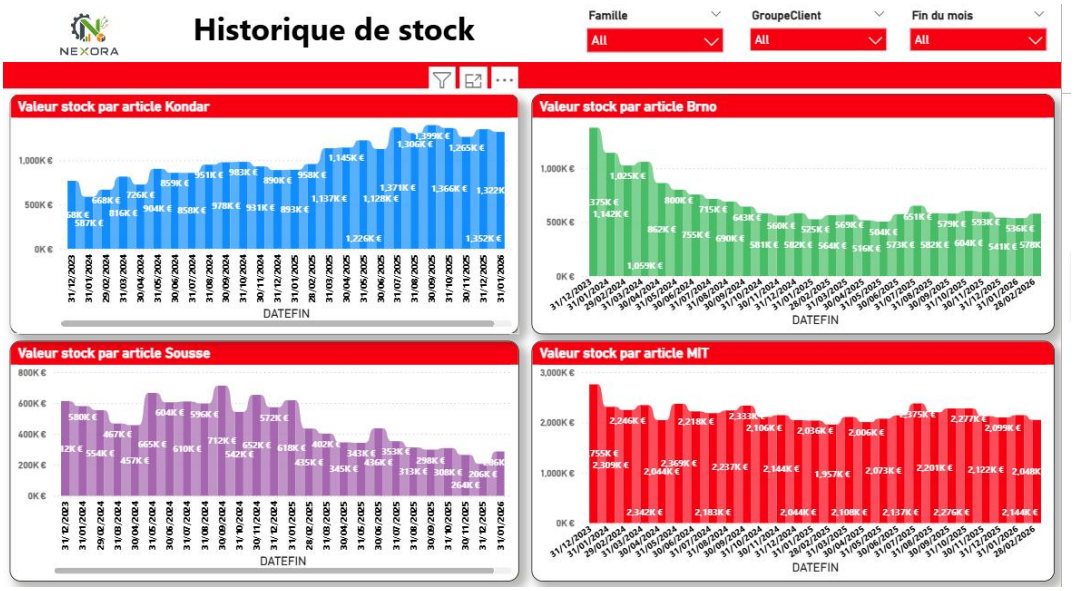


Figure 6.3 : Rapport Power BI « Suivi stock » – page Historique de stock

La figure 6.4 présente l'état du stock à une fin de mois (ici le 30/06/2024) : répartition de la valeur par site (Kondar 39 %, BRNO 34 %, Sousse 27 %) et par famille (PF-PSF 39 %, Matière 32 %, Insert 25 %), tableaux croisés famille × site en valeur et en pourcentage, et valeur par groupe client et par nom abrégé :

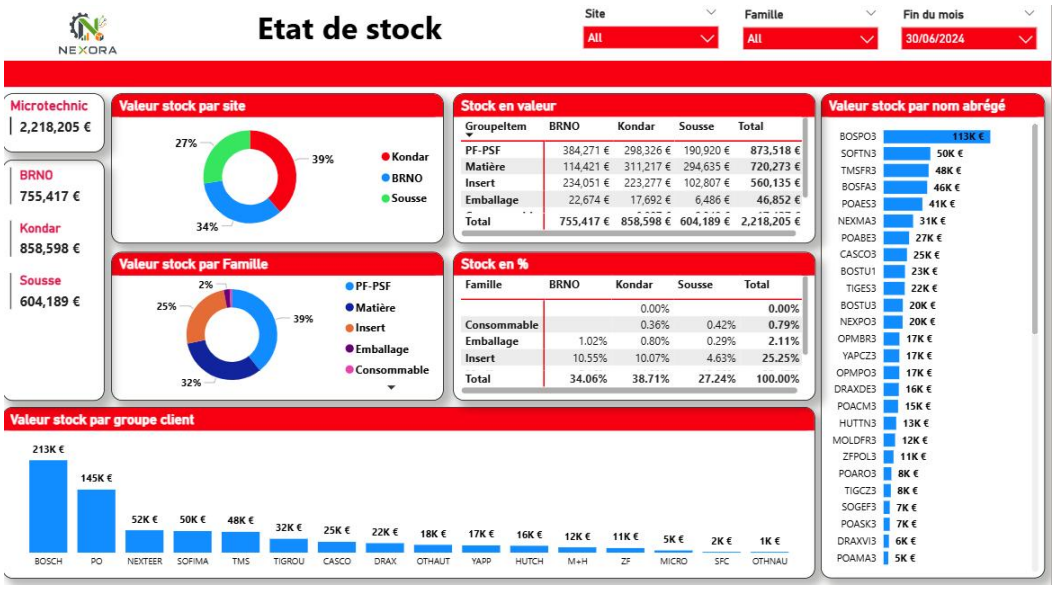


Figure 6.4 : Rapport Power BI « Suivi stock » – page Vue globale (état de stock)

6.4.3 Top 10 des articles par site

La figure 6.5 présente, pour la même date, les dix articles les plus valorisés de chaque site et de l'ensemble MIT, avec leur quantité et leur coût :

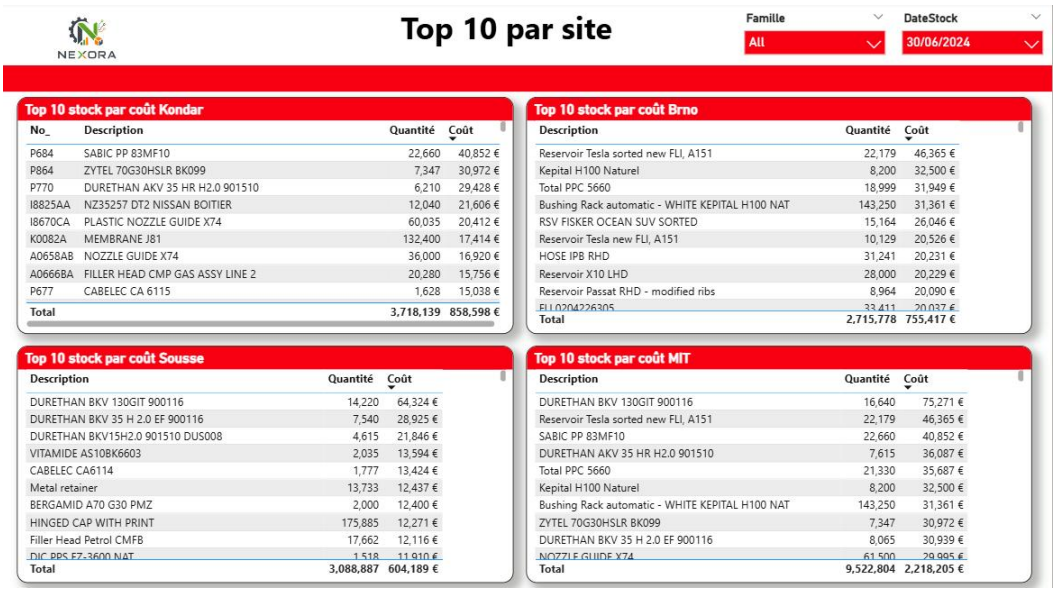


Figure 6.5 : Rapport Power BI « Suivi stock » – page Top 10 par site

6.4.4 Détail du stock à date

La figure 6.6 détaille le stock à une date donnée : tableau famille × site, répartition de la valeur par site et liste des articles avec leur quantité, leur coût, leur part du coût total et leur coût moyen :

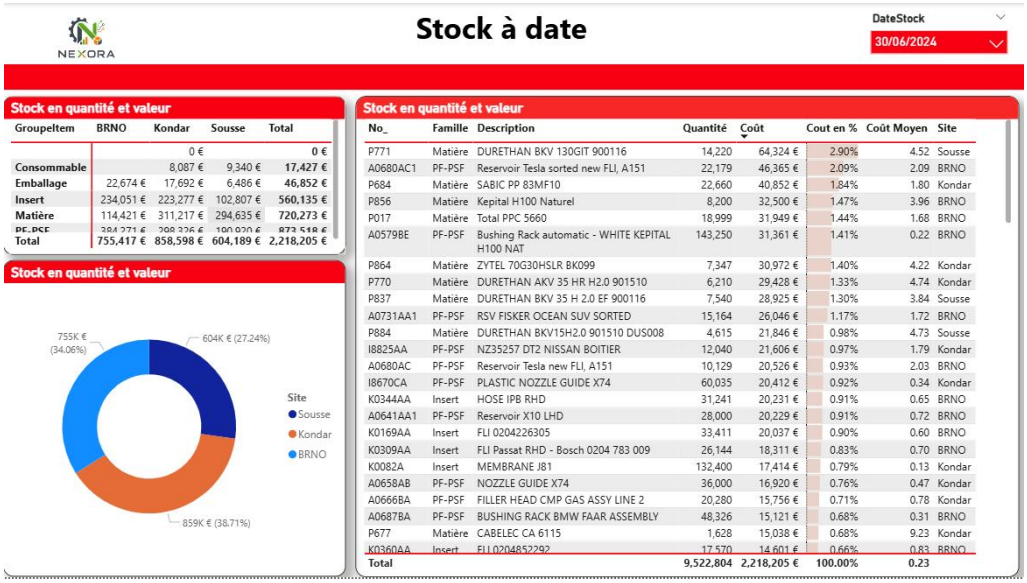


Figure 6.6 : Rapport Power BI « Suivi stock » – page Détail stock (stock à date)

6.4.5 Portail web opérationnel

La plateforme comprend une application web développée avec React [22] côté client et Spring Boot [17] côté serveur. Ce portail offre à l'opérateur d'atelier une interface fluide et réactive pour consulter les données opérationnelles d'inventaire, filtrer les alertes de criticité et suivre les indicateurs de fabrication ; l'administrateur accède en plus aux prévisions et à la gestion des utilisateurs.

6.5 Validation des résultats

6.5.1 Validation des prévisions d'atelier

La validation des prévisions repose sur trois mesures complémentaires : la validation croisée sur 12 plis de 30 jours (du 01/04/2025 au 26/03/2026), qui donne l'erreur moyenne des modèles sur une année (67 927 à 94 635 unités par jour) ; la validation sur le même mois de l'année précédente, qui détermine le modèle utilisé (Random Forest pour mai 2026, avec 33 614 unités par jour d'erreur sur mai 2025) ; et le contrôle sur un mois réel : la prévision de février 2026, calculée avec les données au 31/01/2026, s'écarte de −4,5 % de la production réellement réalisée.

6.5.2 Validation des règles d'approvisionnement

Le plan à 45 jours exclut les 355 articles en surstock et les 18 articles sans consommation, et cible les 325 articles prioritaires (136 ruptures et 189 critiques) pour un budget de 1 095 585 TND, sécurisant la continuité de l'alimentation des lignes de fabrication.

6.6 Bilan du Sprint 4

Le tableau 6.1 récapitule les livrables validés à l'issue du Sprint 4 :

Tâche planifiée	Livrable produit	Statut
Modélisation Power BI	Connexion au Data Warehouse et création des mesures DAX	Réalisé
Tableau de bord web	Indicateurs de production, machines et stock par période (Mois / Année / Tout)	Réalisé
Pages de prévision	Prévision mensuelle du meilleur modèle, comparaison avec l'année N-1 et avec le réel	Réalisé
Rapport Power BI « Suivi stock »	Évolution, répartition et détail du stock (7 pages)	Réalisé
Portail web opérationnel	Application web React / Spring Boot	Réalisé
Validation des résultats	Contrôle des prévisions (février 2026 : −4,5 %) et du plan de réapprovisionnement	Réalisé

Tableau 6.1 : Bilan des livrables du Sprint 4

6.7 Conclusion

Ce chapitre a présenté la conception, le déploiement et la validation des interfaces décisionnelles et opérationnelles de la plateforme Nexora lors du Sprint 4. En combinant un portail web React / Spring Boot, qui restitue la production, les stocks et les prévisions à partir du Data Warehouse, et un rapport Power BI dédié à l'analyse des stocks, la solution comble le fossé entre la modélisation statistique avancée et les opérations industrielles quotidiennes. La conclusion générale suivante synthétise les résultats majeurs du projet, en discute les limites actuelles et esquisse des perspectives d'évolution prometteuses.

CONCLUSION GÉNÉRALE ET PERSPECTIVES

Ce projet de fin d'études a permis de concevoir, développer et valider la plateforme d'aide à la décision Nexora, destinée à moderniser le pilotage de la production et la gestion logistique d'un parc de 319 machines réparties sur trois sites industriels.

L'objectif fondamental était de valoriser l'entrepôt de données opérationnel pour substituer aux calculs manuels et réactifs un système automatisé, prédictif et ergonomique.

L'adoption de la démarche itérative Agile Scrum a permis de rythmer le projet autour de jalons concrets et mesurables :

- Sprint 0 (Cadrage & Architecture) : formalisation des besoins des deux acteurs d'atelier (Opérateur et Administrateur), modélisation des cas d'utilisation UML et conception de l'architecture découplée en quatre couches.
- Sprint 1 (Ingénierie des données & ETL) : conception d'un pipeline Python appliquant dix règles qualité, qui retient 836 319 enregistrements sur 862 065 (97,01 %), ajoute la colonne « Quantité produite TRS » utilisée par les prévisions et charge les données dans des tables intermédiaires du Data Warehouse.
- Sprint 2 (Gestion intelligente des stocks) : classification des 1 410 articles suivis en six statuts (de Rupture à Inactif) selon leur couverture, couplée à une formule de réapprovisionnement à 45 jours qui chiffre l'enveloppe prioritaire des 325 articles en risque (3 671 804 unités pour un budget de 1 095 585 TND).
- Sprint 3 (Modélisation prédictive par IA) : comparaison de quatre modèles (Régression linéaire, ARIMA, Random Forest, Prophet) par validation croisée temporelle, réglage des hyperparamètres et sélection automatique du meilleur modèle sur le même mois de l'année précédente ; Random Forest est retenu pour mai 2026, et la prévision de février 2026 s'écarte de −4,5 % de la production réelle.
- Sprint 4 (Restitution & Validation) : réalisation d'un portail web React / Spring Boot (tableau de bord, production, machines, stock, prévisions) et d'un rapport Power BI de suivi des stocks, avec la validation des prévisions et du plan de réapprovisionnement.

En dépit de ces résultats concluants, notre solution comporte certaines limites méthodologiques et techniques qu'il convient de souligner avec rigueur académique :

- Périmètre temporel d'observation : la modélisation exploite 816 jours (janvier 2024 à mars 2026), soit un peu plus de deux cycles annuels ; la validation sur l'année précédente ne porte donc que sur un mois, et le réglage des hyperparamètres ne s'est pas révélé généralisable sur cet historique. La forte variabilité journalière (coefficient de variation de 65 %) maintient l'erreur moyenne en validation croisée autour de 70 000 unités par jour (MAE).
- Agrégation macroscopique de la prévision : les modèles actuels prévoient la cadence globale au niveau de l'atelier ; ils ne modélisent pas encore individuellement le comportement de chacune des 319 machines ou de chaque moule spécifique.
- Dépendance à la qualité des saisies : la fiabilité des quantités produites, des rebuts et des temps de marche dépend de la rigueur de saisie des déclarations dans le système transactionnel d'origine.

Ces constats ouvrent la voie à plusieurs perspectives d'évolution industrielle à court et moyen termes :

- 1. Modélisation hiérarchique par machine et famille de matière : développer des modèles de séries temporelles hiérarchiques réconciliées (par site, atelier, presse et moule) afin de descendre au niveau de granularité le plus fin pour l'ordonnancement d'atelier.
- 2. Intégration bidirectionnelle avec le moteur MRP de l'ERP : injecter automatiquement les recommandations de commande de stock calculées par Nexora dans le module d'achats de l'ERP pour générer des demandes d'achat pré-remplies.
- 3. Industrialisation MLOps et réentraînement continu : mettre en œuvre un pipeline MLOps automatisé (avec MLflow ou Airflow) détectant la dérive des données (*data drift*) et déclenchant le réapprentissage périodique des modèles prédictifs.
- 4. Système d'alerte multicanal automatisé : déployer un service d'alertes par courrier électronique et notifications push Web/SMS à destination de l'administrateur et des opérateurs dès qu'une couverture de référence descend sous le seuil critique des 15 jours.

En conclusion, ce projet de fin d'études démontre avec succès comment la convergence de l'ingénierie des données, de l'apprentissage automatique et du développement logiciel

moderne peut apporter une réponse concrète, quantifiable et durable aux défis de la performance industrielle.

BIBLIOGRAPHIE

Les références bibliographiques et sources techniques mobilisées dans le cadre de ce projet sont référencées ci-dessous conformément à la norme IEEE :

- [1] K. Schwaber et J. Sutherland, « The Scrum Guide: The Definitive Guide to Scrum: The Rules of the Game », Scrum.org, nov. 2020. https://scrumguides.org
- [2] M. Cohn, User Stories Applied: For Agile Software Development. Boston, MA, USA : Addison-Wesley Professional, 2004.
- [3] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, et G. M. Ljung, Time Series Analysis: Forecasting and Control, 5e éd. Hoboken, NJ, USA : John Wiley & Sons, 2015.
- [4] R. J. Hyndman et G. Athanasopoulos, Forecasting: Principles and Practice, 3e éd. Melbourne, Australie : OTexts, 2021. https://otexts.com/fpp3/
- [5] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow, 2e éd. Sebastopol, CA, USA : O'Reilly Media, 2019.
- [6] T. Hastie, R. Tibshirani, et J. Friedman, The Elements of Statistical Learning: Data Mining, Inference, and Prediction, 2e éd. New York, NY, USA : Springer, 2009.
- [7] L. Breiman, « Random Forests », Machine Learning, vol. 45, n° 1, p. 5-32, 2001.
- [8] R. Kimball et M. Ross, The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling, 3e éd. Indianapolis, IN, USA : John Wiley & Sons, 2013.
- [9] E. A. Silver, D. F. Pyke, et R. Peterson, Inventory Management and Production Planning and Scheduling, 3e éd. New York, NY, USA : John Wiley & Sons, 1998.
- [10] S. Seabold et J. Perktold, « statsmodels: Econometric and statistical modeling with Python », in Proc. of the 9th Python in Science Conference, Austin, TX, USA, 2010, p. 92-96.
- [11] F. Pedregosa et al., « Scikit-learn: Machine Learning in Python », Journal of Machine Learning Research, vol. 12, p. 2825-2830, 2011. https://scikit-learn.org
- [12] S. J. Taylor et B. Letham, « Forecasting at scale: The Prophet procedure », The American Statistician, vol. 72, n° 1, p. 37-45, 2018. https://peerj.com/preprints/3190/

- [13] J. D. Hunter, « Matplotlib: A 2D graphics environment », Computing in Science & Engineering, vol. 9, n° 3, p. 90-95, 2007.
- [14] S. Axsäter, Inventory Control, 3e éd. New York, NY, USA : Springer International Publishing, 2015.
- [15] R. G. Brown, Statistical Forecasting for Inventory Control. New York, NY, USA : McGraw-Hill, 1959.
- [16] Microsoft Corporation, « Microsoft SQL Server 2025 Documentation », 2025. https://learn.microsoft.com/sql/sql-server/
- [17] Spring Framework Team, « Spring Boot 3 Reference Documentation », VMware Tanzu, 2024. https://spring.io/projects/spring-boot
- [18] Python Software Foundation, « Python Documentation, Version 3.10 », 2024. https://docs.python.org/3/
- [19] W. McKinney, « Data Structures for Statistical Computing in Python (Pandas) », in Proc. of the 9th Python in Science Conf., Austin, TX, USA, 2010, p. 56-61. https://pandas.pydata.org
- [20] C. R. Harris et al., « Array programming with NumPy », Nature, vol. 585, p. 357-362, 2020.
- [21] S. Ramirez, « FastAPI: Modern, Fast Web Framework for Python », 2024. https://fastapi.tiangolo.com
- [22] Meta Platforms Inc., « React.js 18 Documentation & Concurrent Features », 2024. https://react.dev
- [23] B. Cherny, Programming TypeScript: Making Your JavaScript Applications Scale. Sebastopol, CA, USA : O'Reilly Media, 2019. https://www.oreilly.com/library/view/programming-typescript/9781491954454/
- [24] A. Ferrari et M. Russo, The Definitive Guide to DAX: Business Intelligence with Microsoft Power BI, SQL Server Analysis Services, and Excel, 2e éd. Redmond, WA, USA : Microsoft Press, 2019.
- [25] G. Booch, J. Rumbaugh, et I. Jacobson, The Unified Modeling Language User Guide, 2e éd. Boston, MA, USA : Addison-Wesley, 2005.